NLP avec R pour les sciences sociales

Sophie Balech

28/05/2024

Table of contents

Introduction **5**
Ressources en ligne 5

I Niveau 1 : Initiation **6**

1 Prise en main **7**
1.1 Introduction 7
1.2 Premières manipulations 7
1.3 Charger des données 7
1.3.1 Un tableau de données 7
1.3.2 Une collection de fichier textes 8
1.3.3 Reconnaissance Optique des Caractères (OCR) 8

2 Pré-traitements **11**
2.1 Introduction 11
2.2 Les données 11
2.3 Premières analyses des données 13

3 Création du corpus et premières observations du corpus **20**

4 Nettoyage du corpus **24**

5 Filtrer le corpus des termes trop fréquents **30**

6 La loi de Zipf **34**

7 Mesures de fréquence **35**
7.1 Pondération tf-idf 35

8 Comprendre le sens des termes **40**

9 Analyse du sentiment **42**

10 Les données **43**

11 *Sentiment analysis* **44**
11.1 Les sentiments 46
11.2 Les émotions 49

12 Évolution du corpus dans le temps **52**

13 Nuage de mots comparés **55**
13.1 En fonction des années 55
13.2 En fonction des sentiments 56

II Niveau 2 : Approfondissements **58**

14 Annotations et dépendances syntaxiques **59**

15 Les données **60**

16 Les traitements préliminaires **62**

17 Co-occurrences **63**
17.1 Représentation en réseau des termes co-occurents 67

18 Annotations **69**
18.1 Détecter les langues 69
18.2 POS 69

19 Les dépendances syntaxiques **76**

20 *Topic Analysis* **78**

21 Les données **79**

22 *Topics Analysis* **80**
22.1 Le modèle LDA avec topicmodels 81
22.2 *Topic Analysis* à partir de l'annotation des *part of speech* 82
22.3 Déterminer le nombre de topics optimal 84
22.4 Représentation graphique 87

23 *Theory-Driven LDA* **89**

24 Expliquer les notes **93**
24.1 NPS 93
24.2 En fonction des topics 99

Appendices **102**

A Webscraping **102**

References **107**

Introduction

Ceci est le support pour le cours “NLP avec R pour les sciences sociales” réalisé auprès des doctorants de l’école doctorale SHS de l’UPJV.

L’objectif est de donner aux apprenants des méthodes et outils pour traiter de larges corpus de texte pour répondre à leur problématique de recherche.

L’environnement de traitement des données est R et Rstudio.

Ici, une présentation en guise d’introduction.

Ressources en ligne

R et RStudio

- https://www.r-project.org/
- https://rstudio.com/products/rstudio/

Des ressources en ligne

- Introduction à R et au tidyverse
- R for data science
- Hands-On Programming with R
- Text mining with R
- Tutoriels Quanteda
- Les techniques du NLP pour la recherche en sciences de gestion
- NLP avec r et en français - un Manuel synthétique
- Quarto pour communiquer
- Le séminaire du Collège de France : Apprendre les langues aux machines - B. Sagot

Part I

Niveau 1 : Initiation

1 Prise en main

1.1 Introduction

Le document de travail contient deux types d'éléments : du texte pour expliquer et présenter ce que l'on fait et du code pour réaliser les manipulations de données, les analyses et les graphiques. On commence toujours un document avec un bloc de code de setup, pour lister et charger les packages que l'on va utiliser et les options générales pour l'édition du document.

La publication des documents peut se faire en différents formats : html, word, pdf (via latex), présentation html (via revealjs), présentation powerpoint, présentation beamer(via latex), … On se référera au site de Quarto pour plus de détails.

Ici, on commence simplement avec quelques manipulations pour comprendre l'environnement de travail, puis on verra comment charger des données sous différents formats.

1.2 Premières manipulations

- Créer un document script (.R) : pour simplement éditer du code
- Créer un document quarto (.qmd) : pour mixer du code et du texte
- Commenter du code
- Afficher de l'aide sur une fonction

1.3 Charger des données

1.3.1 Un tableau de données

Fichier .csv, .xlsx, .rds

```
data<-read.csv("le/chemin/de/mon/fichier.csv")

library(readxl)
data<-read_xlsx("le/chemin/de/mon/fichier.xlsx")
```

```
library(readr)
data<- read_rds("le/chemin/de/mon/fichier.rds")
```

1.3.2 Une collection de fichier textes

Un dossier avec plusieurs fichier .txt ou .docx ou .pdf

```
library(readtext)
#Exemple de nom de document : "int1_2024_dirigeant.txt"
data<-readtext("le/chemin/de/mes/fichiers/*.txt",
         docvarsfrom = "filenames",
         docvarnames = c("int", "année", "type"),
         dvsep = "_")

data<-readtext("le/chemin/de/mes/fichiers/*.docx")

data<-readtext("le/chemin/de/mes/fichiers/*.pdf")
```

Pour les problèmes de mise en forme, on consultera la vignette du package readtext.

Une autre solution pour les fichiers pdf, permettant d'enlever tous les éléments de mise en forme :

```
library(tm)
#on récupère les noms des fichiers à lire depuis les dossiers
files <- list.files( pattern = "pdf$", recursive = T, include.dirs = T)

#on lit les fichiers, sans la mise en forme
corp<-Corpus(URISource(files),
               readerControl = list(reader = readPDF, text=("-layout")))
#on enlève les sauts de page et autres mises en forme à partir d'espace
corp <- tm_map(corp, stripWhitespace)
```

Un autre outil pour les pdf : le package pdftools.

1.3.3 Reconnaissance Optique des Caractères (OCR)

Pour ça, on utilise le package tesseract :

Exemple avec cette image :

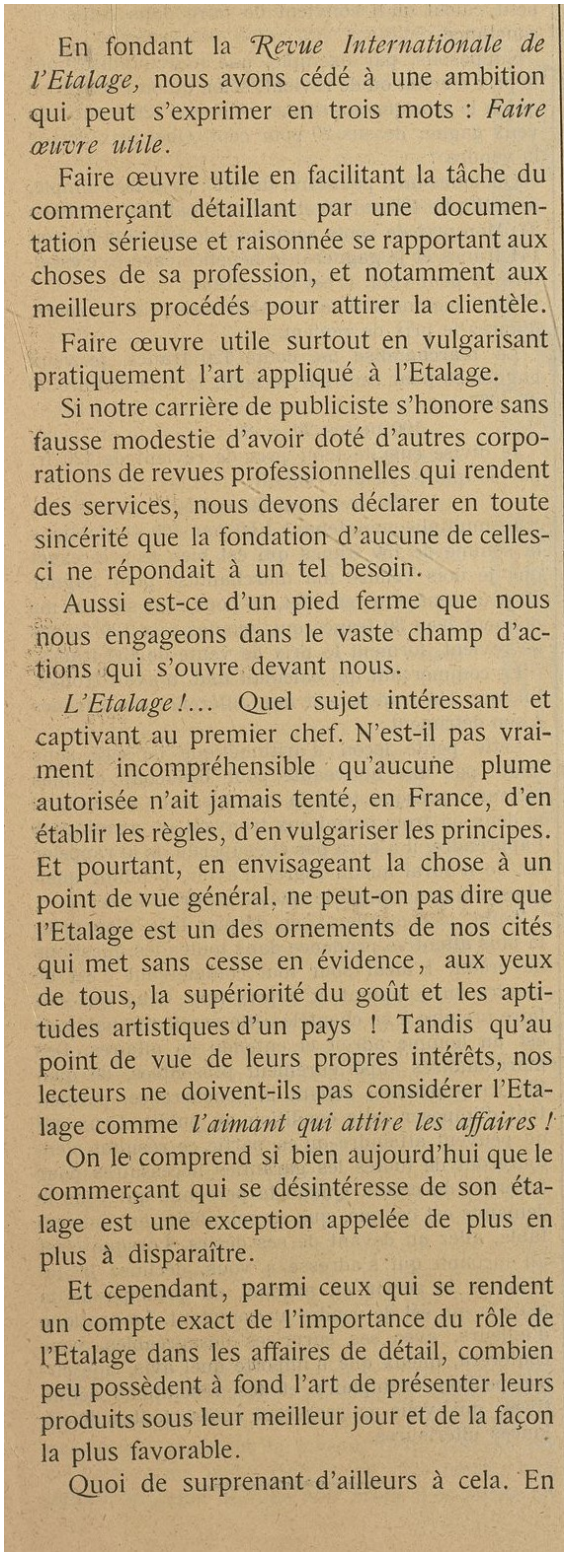

En fondant la *Revue Internationale de l'Etalage,* nous avons cédé à une ambition qui peut s'exprimer en trois mots : *Faire œuvre utile.*

Faire œuvre utile en facilitant la tâche du commerçant détaillant par une documentation sérieuse et raisonnée se rapportant aux choses de sa profession, et notamment aux meilleurs procédés pour attirer la clientèle.

Faire œuvre utile surtout en vulgarisant pratiquement l'art appliqué à l'Etalage.

Si notre carrière de publiciste s'honore sans fausse modestie d'avoir doté d'autres corporations de revues professionnelles qui rendent des services, nous devons déclarer en toute sincérité que la fondation d'aucune de celles-ci ne répondait à un tel besoin.

Aussi est-ce d'un pied ferme que nous nous engageons dans le vaste champ d'actions qui s'ouvre devant nous.

L'Etalage !... Quel sujet intéressant et captivant au premier chef. N'est-il pas vraiment incompréhensible qu'aucune plume autorisée n'ait jamais tenté, en France, d'en établir les règles, d'en vulgariser les principes. Et pourtant, en envisageant la chose à un point de vue général, ne peut-on pas dire que l'Etalage est un des ornements de nos cités qui met sans cesse en évidence, aux yeux de tous, la supériorité du goût et les aptitudes artistiques d'un pays ! Tandis qu'au point de vue de leurs propres intérêts, nos lecteurs ne doivent-ils pas considérer l'Etalage comme *l'aimant qui attire les affaires !*

On le comprend si bien aujourd'hui que le commerçant qui se désintéresse de son étalage est une exception appelée de plus en plus à disparaître.

Et cependant, parmi ceux qui se rendent un compte exact de l'importance du rôle de l'Etalage dans les affaires de détail, combien peu possèdent à fond l'art de présenter leurs produits sous leur meilleur jour et de la façon la plus favorable.

Quoi de surprenant d'ailleurs à cela. En

```r
library(tesseract)
tesseract_download("fra") #pour télécharger le modèle de langage

text <- tesseract::ocr("N1_avril1909b.jpeg", engine = "fra")

cat(text) #pour afficher le texte avec sa mise en page
```

2 Pré-traitements

2.1 Introduction

Le document de travail contient deux types d'éléments : du texte pour expliquer et présenter ce que l'on fait et du code pour réaliser les manipulations de données, les analyses et les graphiques. On commence toujours un document avec un bloc de code de setup, pour lister et charger les packages que l'on va utiliser et les options générales pour l'édition du document.

```
library(readxl)
library(tidyverse)
library(quanteda)
library(quanteda.textstats)
library(quanteda.textplots)
library(RColorBrewer)
```

Dans un premier temps, nous allons tout simplement charger la base de données de travail puis la décrire. Ensuite, nous créerons un corpus, le visualisons. Puis nous effectueront quelques analyses liminaires, avant de voir les pré-traitements à réaliser sur le corpus.

2.2 Les données

```
#On charge les données, stockées dans un fichier csv

data <- read_csv("data/data_trustpilot_oiseaux.csv")
```

```
Rows: 4388 Columns: 7
-- Column specification --------------------------------------------------------
Delimiter: ","
chr (4): auteur, date, month, comments
dbl (3): id, year, note

i Use `spec()` to retrieve the full column specification for this data.
i Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

```r
names(data)
```

```
[1] "id"       "auteur"   "date"     "month"    "year"     "note"     "comments"
```

```r
view(data)
data
```

```
# A tibble: 4,388 x 7
      id auteur                   date            month    year  note comments
   <dbl> <chr>                    <chr>           <chr>   <dbl> <dbl> <chr>
 1     1 MAQUET Cyril             07 août 2023    août     2023     5 "Comme to~
 2     2 Mme Laurence  Wolff      08 août 2023    août     2023     5 "Le délai~
 3     3 Une nouvelle cliente     07 août 2023    août     2023     5 "Produits~
 4     4 Patricia ALLAMAN         15 août 2023    août     2023     5 "Envoi ra~
 5     5 VPL                      24 juillet 2023 juillet  2023     5 "Expéditi~
 6     6 PHILIPPE GODIN           08 août 2023    août     2023     5 "site sér~
 7     7 Mme MARIA ADILIA PEREIRA 15 août 2023    août     2023     1 "deux sem~
 8     8 Rachel Mattyssen         31 juillet 2023 juillet  2023     5 "Très bie~
 9     9 Estelle Fay              16 juillet 2023 juillet  2023     5 "Enfin un~
10    10 Mme T.                   06 août 2023    août     2023     4 "Satisfai~
# i 4,378 more rows
```

```r
#Résumé des données
summary(data)
```

```
       id          auteur              date              month
 Min.   :   1   Length:4388        Length:4388        Length:4388
 1st Qu.:1098   Class :character   Class :character   Class :character
 Median :2194   Mode  :character   Mode  :character   Mode  :character
 Mean   :2194
 3rd Qu.:3291
 Max.   :4388
      year           note         comments
 Min.   :2013   Min.   :1.000   Length:4388
 1st Qu.:2018   1st Qu.:5.000   Class :character
 Median :2020   Median :5.000   Mode  :character
 Mean   :2019   Mean   :4.641
 3rd Qu.:2021   3rd Qu.:5.000
 Max.   :2023   Max.   :5.000
```

2.3 Premières analyses des données

Avant de s'intéresser au contenu des commentaires, explorons la structure des données. On va regarder la distribution des commentaires et des notes dans le temps, et s'intéresser à la longueur des avis clients.

```
#Les années
data$year<-as.factor(data$year)
summary(data$year)
```

```
2013 2014 2015 2016 2017 2018 2019 2020 2021 2022 2023
 125  209  249  171  324  341  375  735  853  623  383
```

```
data%>%
  group_by(year)%>%
  summarise(n=n(), prop=n/nrow(data))%>%
  ggplot(aes(year,prop))+
  geom_col(fill="green",show.legend = TRUE)+
  scale_y_continuous(labels = scales::percent)+
  theme_light()+
  labs(title = "Répartition des avis dans le temps", subtitle = "Corpus Oiseaux Mania", capti
```

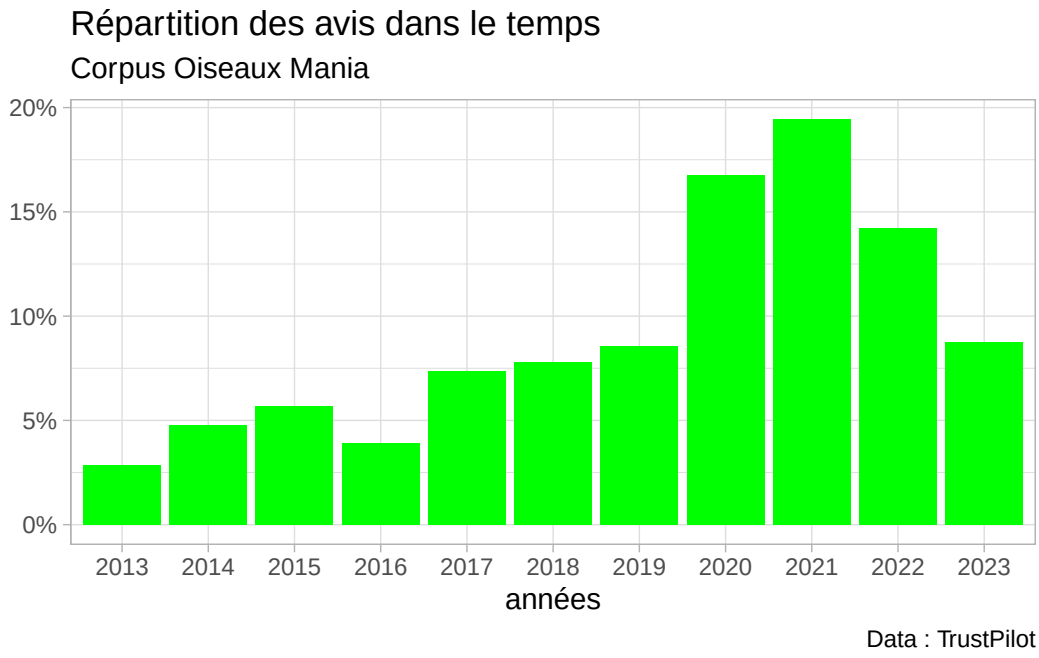

```r
#Les notes
summary(data$note)
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max. 
  1.000   5.000   5.000   4.641   5.000   5.000 
```

```r
summary(as.factor(data$note))
```

```
   1    2    3    4    5 
 116   62  169  589 3452 
```

```r
data%>%
  group_by(note)%>%
  summarise(n=n(), prop=n/nrow(data))%>%
  ggplot(aes(note,prop))+
  geom_col(fill=c("red","pink","orange","gold","lightgreen"))+
  annotate("text", x=2, y=0.7, label=paste("Note moyenne = ",round(mean(data$note),1)))+
  scale_y_continuous(labels=scales::percent)+
  theme_light()+
  labs(title = "Répartition des avis en fonction des notes", subtitle = "Corpus Oiseaux Mania
```

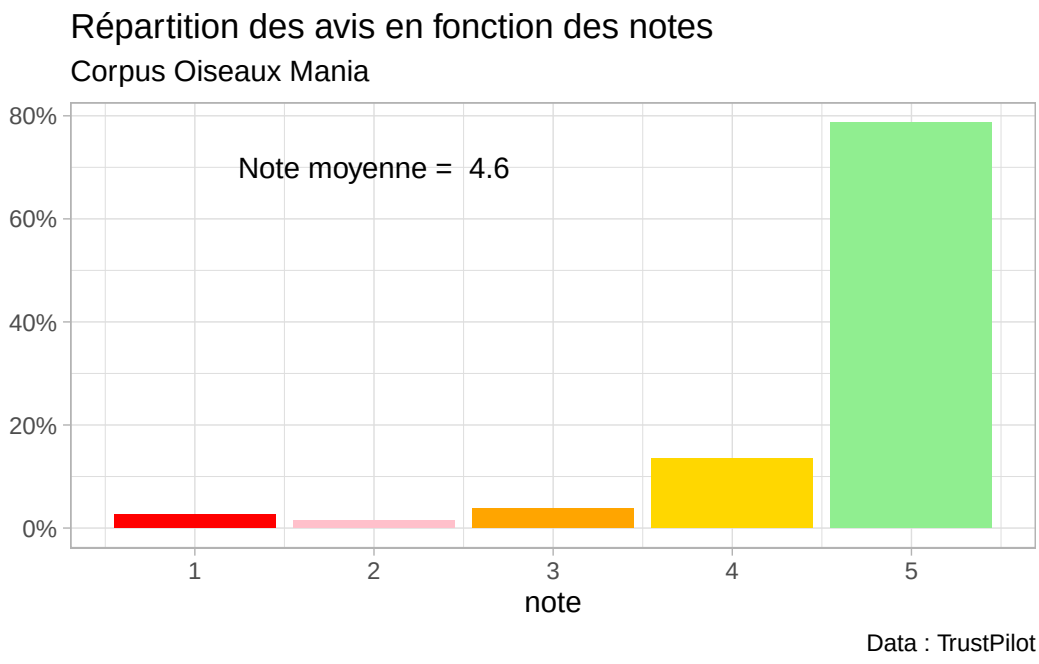

```r
#Le nombre de caractère
data$nb_caractere<-nchar(data$comments) #on compte le nombre de caractère de chaque commentai
summary(data$nb_caractere)
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   12.0    41.0    74.0   104.3   130.0  1571.0
```

```r
ggplot(data, aes(nb_caractere))+
  geom_boxplot()+
  scale_y_continuous(NULL, breaks = NULL)+
  labs(x=NULL,title = "Nombre de caractères des avis", subtitle = "Corpus Oiseaux Mania", ca
  theme_light()+
  coord_flip()
```

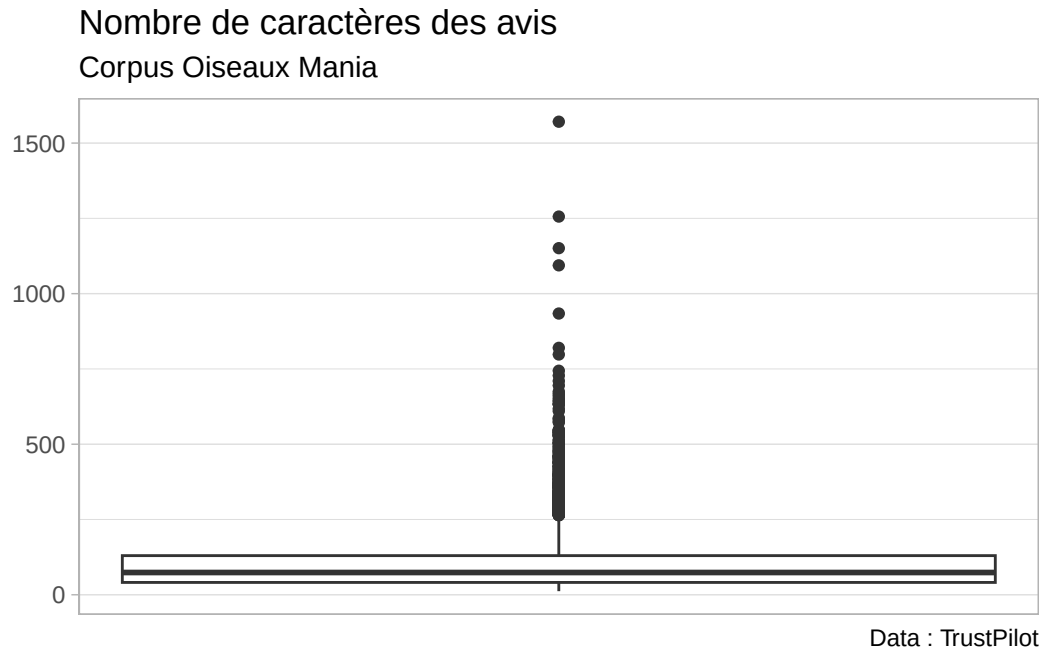


```r
#Le nombre de tokens

data$nb_token<-ntoken(data$comments) #on compte le nombre de caractère de chaque commentaire
```

```
Warning: ntoken.character()/ntype.corpus() was deprecated in quanteda 4.0.0.
i Please use ntoken(tokens(x)) instead.
```

```
summary(data$nb_token)
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max. 
    2.0     7.0    13.0    19.3    24.0   308.0 
```

```
ggplot(data, aes(nb_token))+
  geom_boxplot()+
  scale_y_continuous(NULL, breaks = NULL)+
  labs(x=NULL,title = "Nombre de tokens des avis", subtitle = "Corpus Oiseaux Mania", captio
  theme_light()+
  coord_flip()
```

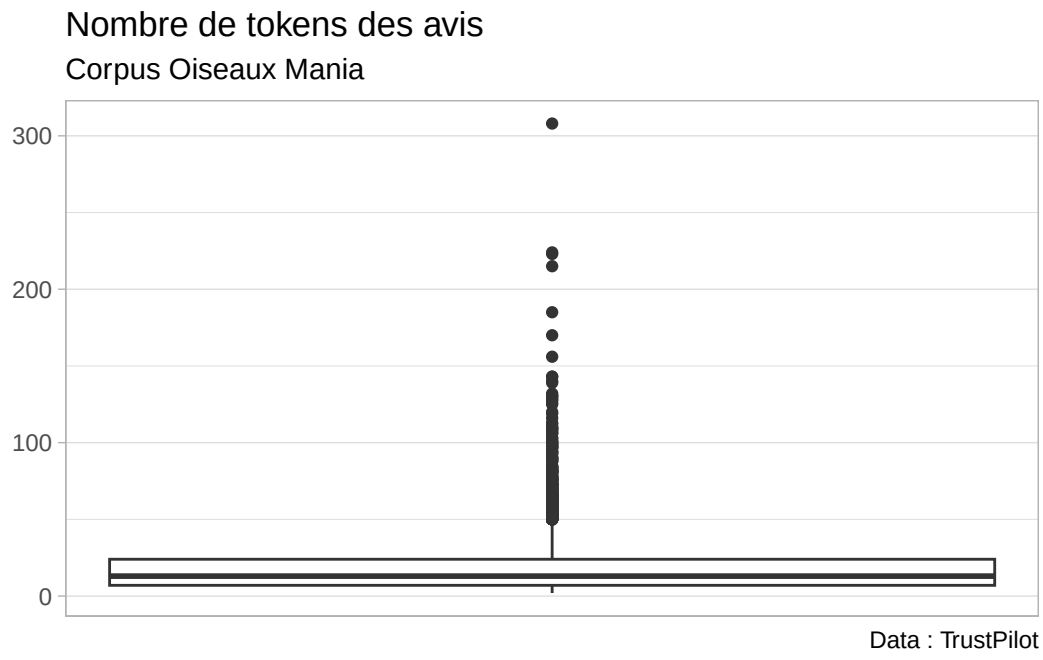


```
#On va filtrer au-dessus de 100 tokens
data_100t<-data%>%filter(nb_token<50)

ggplot(data_100t, aes(nb_token))+
  geom_boxplot()+
  scale_y_continuous(NULL, breaks = NULL)+
  labs(x=NULL,title = "Nombre de tokens des avis", subtitle = "Corpus Oiseaux Mania", captio
  theme_light()+
  coord_flip()
```

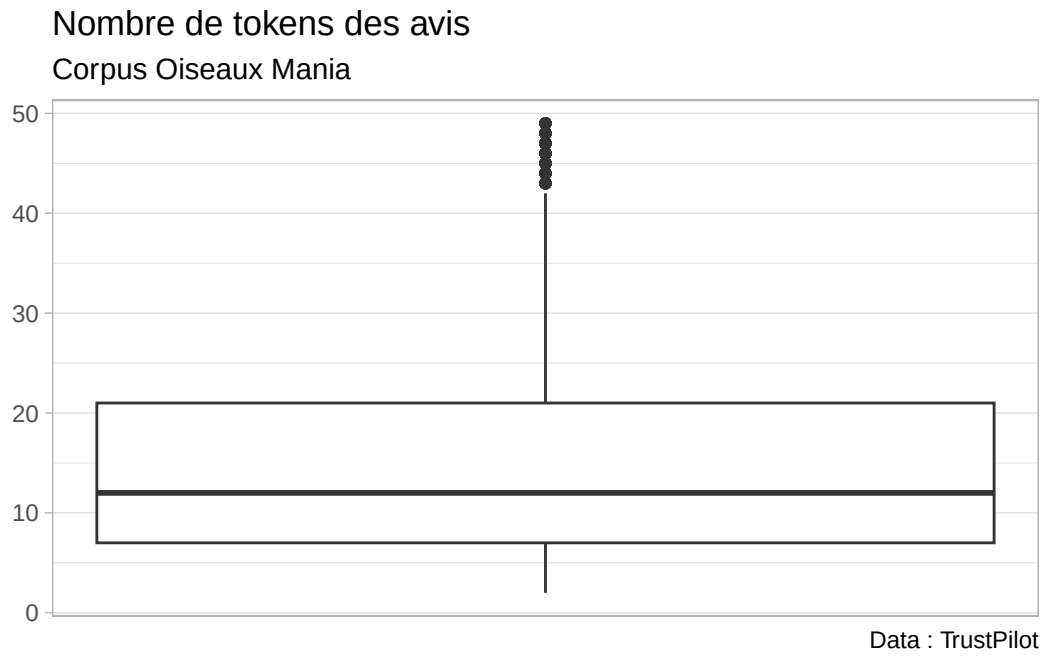


```
#Les notes dans le temps
data%>%
  mutate(note=as.factor(note))%>%
  group_by(year, note)%>%
  summarise(n=n() ,prop=n/nrow(data))%>%
  ggplot(aes(year, prop))+
  geom_col(aes(fill=note), show.legend = FALSE)+
  scale_fill_discrete(type=c("red","pink","orange","gold","lightgreen"))+
  scale_y_continuous(labels=scales::percent)+
  theme_light()+
  labs(title = "Répartition des avis dans le temps", subtitle = "Corpus Oiseaux Mania", capti
```

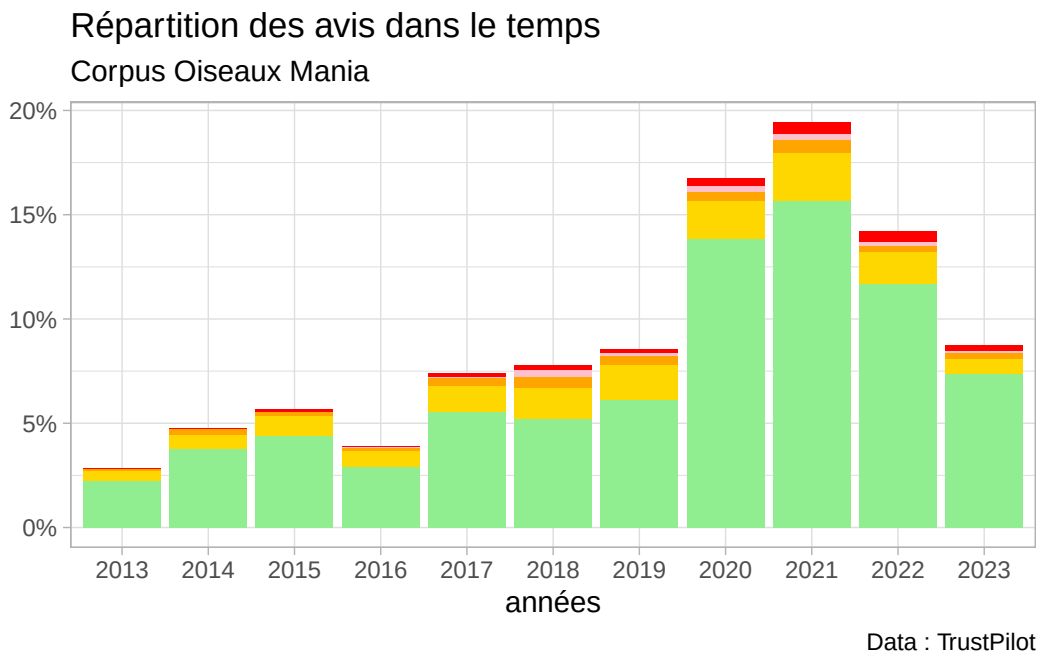


```
data%>%
  mutate(note=as.factor(note))%>%
  group_by(year, note)%>%
  summarise(n=n())%>%
  ggplot(aes(x=year, y=n, group=note))+
  geom_bar(position="fill",stat="identity", aes(fill=note))+
  scale_fill_discrete(type=c("red","pink","orange","gold","lightgreen"))+
  scale_y_continuous(labels=scales::percent)+
  theme_minimal()+
  labs(title = "Comparaison de la répartition des notes dans le temps", subtitle = "Corpus O
```

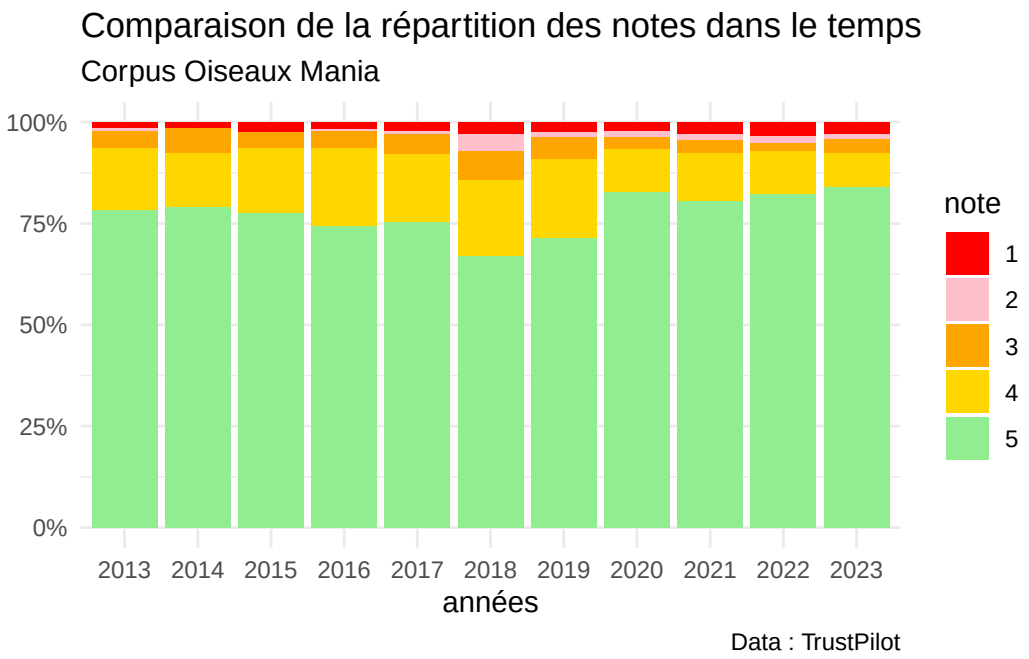
Comparaison de la répartition des notes dans le temps
Corpus Oiseaux Mania
100%
75%
50%
25%
0%
2013
2014
2015
2016
2017
2018
2019
2020
2021
2022
2023
années
note
1
2
3
4
5
Data : TrustPilot

3 Création du corpus et premières observations du corpus

Tout d'abord, nous transformons le jeu de données en corpus. La variable qui contient le texte est "comments", les autres variables vont devenir des métadonnées du corpus, c'est-à-dire des variables associées à chaque texte. Cela sera utile par le suite pour faire des analyses comparatives entre les textes suivant différentes variables (le temps en particulier, mais pas seulement).

```
#Création du corpus
corpus_oiseaux<-corpus(data, text_field = "comments")
corpus_oiseaux
```

```
Corpus consisting of 4,388 documents and 8 docvars.
text1 :
"Comme toujours, super service. Ne changez rien!(sauf peut êt..."

text2 :
"Le délai de ma commande super rapide Le délais des ma comman..."

text3 :
"Produits de qualité et équipe professionnelle … Très bon acc..."

text4 :
"Envoi rapide, bien emballé et conforme à l'annonce"

text5 :
"Expédition internationale ! J'ai récemment déménagé en Espag..."

text6 :
"site sérieux bon produit livraisons plus que correct mais pe..."

[ reached max_ndoc ... 4,382 more documents ]
```

```
corpus_oiseaux["text600"] #pour visualiser un texte précis
```

```
Corpus consisting of 1 document and 8 docvars.
text600 :
"Commande reçu dans les temps pas de surprise. Très bon site"
```

```
a<-corpus_oiseaux["text30"]
rm(a)
```

Ensuite, nous allons extraire de chaque texte les termes qui les composent. Ces termes sont nommés “token” (jeton), et comme vous pouvez le voir, ce ne sont pas uniquement des mots, mais tout caractère ou suite de caractères séparés des autres par un espace.

```
#Extraction des tokens
tok<-tokens(corpus_oiseaux)
tok["text600"]
```

```
Tokens consisting of 1 document and 8 docvars.
text600 :
 [1] "Commande" "reçu"     "dans"     "les"      "temps"    "pas"
 [7] "de"       "surprise" "."        "Très"     "bon"      "site"
```

Chaque texte est maintenant décomposé en une suite de tokens. Pour voir les termes les plus fréquents dans le corpus, ainsi que leur co-occurrences (apparition de deux termes en même temps), il convient de transformer l’objet tok en une matrice termes-documents. En ligne, tous les tokens identifiés, en ligne, tous les textes du corpus, et les valeurs correspondent au nombre d’occurrences (d’apparitions) de chaque token dans chaque document. Une particularité de cette matrice est qu’elle contient énormément de zéro.

```
#Transformation en document-term frequency matrix
dfm<-dfm(tok)
dfm
```

```
Document-feature matrix of: 4,388 documents, 5,658 features (99.72% sparse) and 8 docvars.
       features
docs    comme toujours , super service . ne changez rien !
  text1     1        1 1     1       1 4  1       1    1 1
  text2     0        1 1     2       0 3  0       0    0 0
  text3     0        0 0     0       0 2  0       0    0 0
  text4     0        0 1     0       0 0  0       0    0 0
```

```
  text5     0        0 4     0       0 2  1       0    0 4
  text6     0        0 0     0       0 0  0       0    0 0
[ reached max_ndoc ... 4,382 more documents, reached max_nfeat ... 5,648 more features ]
```

Enfin, nous pouvons avoir un aperçu des termes les plus fréquents. Nous les visualisons d'abord sous forme de tableau (les 20 tokens les plus fréquents), puis sous la forme d'un nuage de mots, où la taille des mots correspond à leur fréquence dans le corpus.

```
#Visualisation des termes les plus fréquents
textstat_frequency(dfm, n=20) #les 20 premiers termes les plus fréquents
```

```
     feature frequency rank docfreq group
1          .      4777    1    2094   all
2          ,      2788    2    1576   all
3         de      2685    3    1646   all
4         et      2530    4    1915   all
5       très      1996    5    1529   all
6     rapide      1659    6    1569   all
7         je      1622    7    1221   all
8  livraison      1412    8    1299   all
9          !      1349    9     649   all
10         à      1312   10    1022   all
11  commande      1238   11    1030   all
12        le      1215   12     812   all
13        la      1215   12     868   all
14      pour      1049   14     782   all
15       les      1013   15     754   all
16      bien       920   16     803   all
17        en       801   17     618   all
18      site       793   18     686   all
19  produits       738   19     661   all
20        un       729   20     565   all
```

```
textplot_wordcloud(dfm) #nuage de mots
```

```
Warning in text.default(x1, y1, word[i], cex = (1 + adjust) * size[i], offset =
0, : font metrics unknown for Unicode character U+1F44D
```

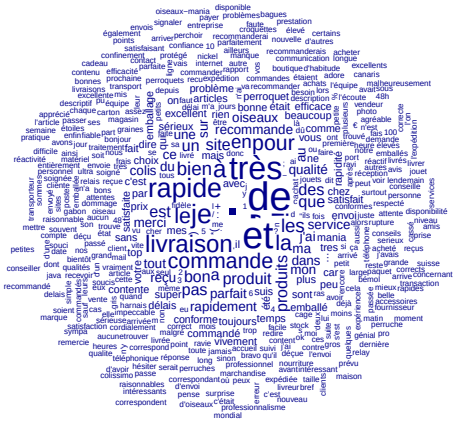

Pour conclure sur cette première approche du corpus, nous voyons que nos analyses sont gênées par la présence de la ponctuation et de plein de petits mots “vides de sens” (les articles par exemple). C’est pourquoi nous allons nettoyer le corpus pour avoir une meilleure vision de ce qu’il contient.

4 Nettoyage du corpus

Le nettoyage du corpus pour les analyses se fait lors de la transformation en tokens. Nous allons ajouter des options pour supprimer la ponctuation, les chiffres et les stopwords (les mots qui n'apportent pas de sens sémantique mais permettent l'articulation du discours).

```
stopwords("fr")
```

```
  [1] "au"       "aux"      "avec"     "ce"       "ces"      "dans"
  [7] "de"       "des"      "du"       "elle"     "en"       "et"
 [13] "eux"      "il"       "je"       "la"       "le"       "leur"
 [19] "lui"      "ma"       "mais"     "me"       "même"     "mes"
 [25] "moi"      "mon"      "ne"       "nos"      "notre"    "nous"
 [31] "on"       "ou"       "par"      "pas"      "pour"     "qu"
 [37] "que"      "qui"      "sa"       "se"       "ses"      "son"
 [43] "sur"      "ta"       "te"       "tes"      "toi"      "ton"
 [49] "tu"       "un"       "une"      "vos"      "votre"    "vous"
 [55] "c"        "d"        "j"        "l"        "à"        "m"
 [61] "n"        "s"        "t"        "y"        "été"      "étée"
 [67] "étées"    "étés"     "étant"    "suis"     "es"       "est"
 [73] "sommes"   "êtes"     "sont"     "serai"    "seras"    "sera"
 [79] "serons"   "serez"    "seront"   "serais"   "serait"   "serions"
 [85] "seriez"   "seraient" "étais"    "était"    "étions"   "étiez"
 [91] "étaient"  "fus"      "fut"      "fûmes"    "fûtes"    "furent"
 [97] "sois"     "soit"     "soyons"   "soyez"    "soient"   "fusse"
[103] "fusses"   "fût"      "fussions" "fussiez"  "fussent"  "ayant"
[109] "eu"       "eue"      "eues"     "eus"      "ai"       "as"
[115] "avons"    "avez"     "ont"      "aurai"    "auras"    "aura"
[121] "aurons"   "aurez"    "auront"   "aurais"   "aurait"   "aurions"
[127] "auriez"   "auraient" "avais"    "avait"    "avions"   "aviez"
[133] "avaient"  "eut"      "eûmes"    "eûtes"    "eurent"   "aie"
[139] "aies"     "ait"      "ayons"    "ayez"     "aient"    "eusse"
[145] "eusses"   "eût"      "eussions" "eussiez"  "eussent"  "ceci"
[151] "cela"     "celà"     "cet"      "cette"    "ici"      "ils"
[157] "les"      "leurs"    "quel"     "quels"    "quelle"   "quelles"
[163] "sans"     "soi"
```

```
tok<-tokens(corpus_oiseaux, remove_punct = TRUE, remove_numbers = TRUE)%>%
  tokens_remove(stopwords("fr"))
corpus_oiseaux["text600"]
```

```
Corpus consisting of 1 document and 8 docvars.
text600 :
"Commande reçu dans les temps pas de surprise. Très bon site"
```

```
tok["text600"]
```

```
Tokens consisting of 1 document and 8 docvars.
text600 :
[1] "Commande" "reçu"     "temps"    "surprise" "Très"     "bon"      "site"
```

Ensuite, on transforme en dfm et on visualise ce que ça donne.

```
dfm<-dfm(tok)
dfm
```

```
Document-feature matrix of: 4,388 documents, 5,430 features (99.81% sparse) and 8 docvars.
       features
docs    comme toujours super service changez rien sauf peut être là
  text1     1        1     1       1       1    1    1    1    1  1
  text2     0        1     2       0       0    0    0    0    0  1
  text3     0        0     0       0       0    0    0    0    0  0
  text4     0        0     0       0       0    0    0    0    0  0
  text5     0        0     0       0       0    0    0    0    0  0
  text6     0        0     0       0       0    0    0    0    0  0
[ reached max_ndoc ... 4,382 more documents, reached max_nfeat ... 5,420 more features ]
```

```
textstat_frequency(dfm, n=20)
```

```
      feature frequency rank docfreq group
1        très      1996    1    1529   all
2      rapide      1659    2    1569   all
3   livraison      1412    3    1299   all
4    commande      1238    4    1030   all
5        bien       920    5     803   all
6        site       793    6     686   all
```

```
7    produits       738    7      661    all
8           a       706    8      566    all
9     produit       676    9      609    all
10        bon       639   10      575    all
11      merci       553   11      529    all
12 recommande       553   11      534    all
13    parfait       522   13      474    all
14    qualité       487   14      447    all
15       j'ai       382   15      289    all
16    oiseaux       379   16      319    all
17       tout       375   17      347    all
18       reçu       362   18      332    all
19      colis       360   19      313    all
20 rapidement       356   20      343    all
```

```
textplot_wordcloud(dfm)
```

```
Warning in text.default(x1, y1, word[i], cex = (1 + adjust) * size[i], offset =
0, : font metrics unknown for Unicode character U+1F44D
```

```r
g<-textstat_frequency(dfm,n=20)


ggplot(g, aes(x = feature, y=frequency))+
  geom_col()+
  coord_flip()
```

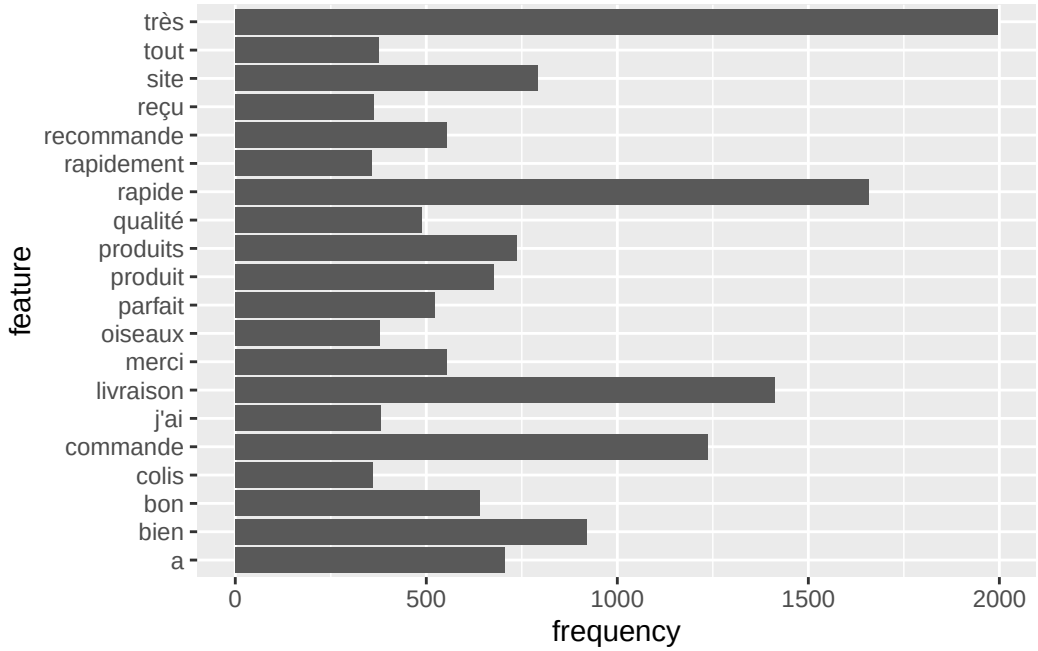


```r
ggplot(g, aes(x = reorder(feature, frequency), y=frequency, fill=frequency))+
  geom_col(show.legend = TRUE)+
  coord_flip()+
  theme_light()+
  scale_fill_distiller(palette = "Blues", direction = 1)+
  labs(title="Les mots les plus fréquents",subtitle = "du corpus Oiseaux Mania",caption = "So
  xlab(NULL)+
  ylab("Fréquence")
```

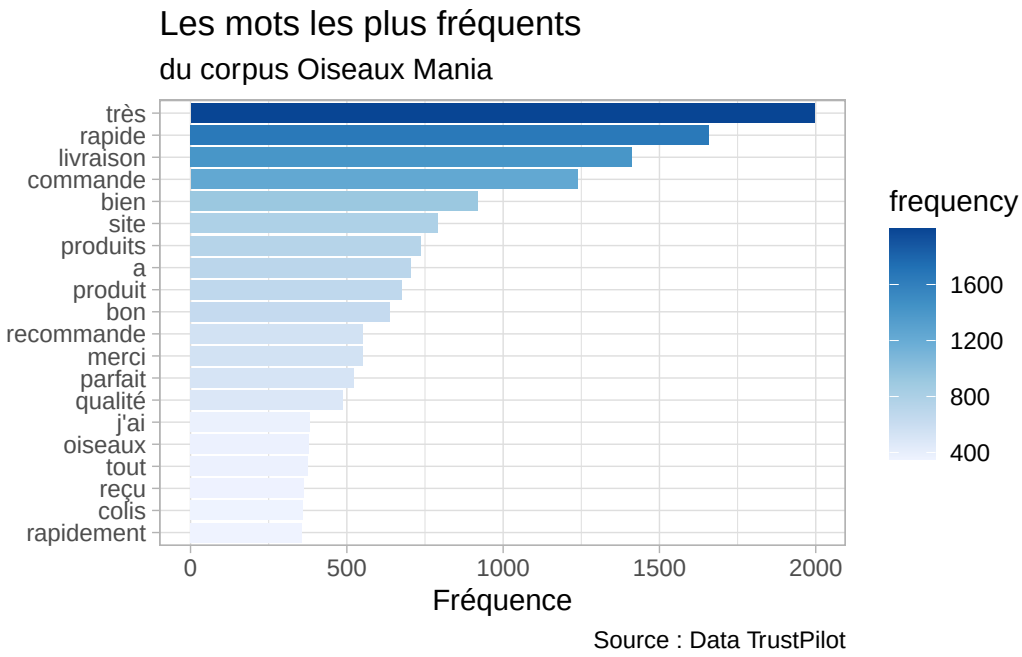


```
display.brewer.all()
```

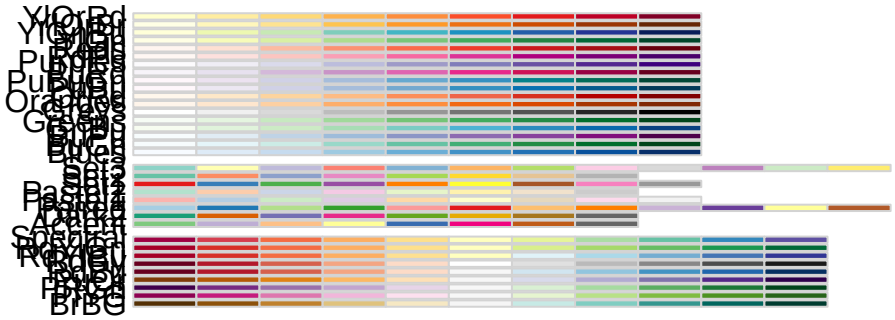

Globalement, la commande et la livraison sont TRÈS rapides et les produits sont bons. La surreprésentation de ces termes dans le corpus nous empêche de voir les thématiques abordées

de manière moins évidentes. Nous avons plusieurs solutions qui s'offrent à nous : filtrer les mots trop fréquents du corpus ou nous intéresser à une autre mesure de la fréquence d'apparition. Nous allons d'abord filtrer le corpus.

On peut aussi vouloir remplacer des termes par d'autres, comme ici "produits" par "produit".

```
tok<-tokens_replace(tok, "produits", "produit")
dfm<-dfm(tok)
textstat_frequency(dfm, n=20)
```

```
      feature frequency rank docfreq group
1        très      1996    1    1529   all
2      rapide      1659    2    1569   all
3     produit      1414    3    1243   all
4   livraison      1412    4    1299   all
5    commande      1238    5    1030   all
6        bien       920    6     803   all
7        site       793    7     686   all
8           a       706    8     566   all
9         bon       639    9     575   all
10      merci       553   10     529   all
11 recommande       553   10     534   all
12    parfait       522   12     474   all
13    qualité       487   13     447   all
14       j'ai       382   14     289   all
15    oiseaux       379   15     319   all
16       tout       375   16     347   all
17       reçu       362   17     332   all
18      colis       360   18     313   all
19 rapidement       356   19     343   all
20    service       351   20     325   all
```

5 Filtrer le corpus des termes trop fréquents

Nous allons filtrer les mots qui sont présents plus de 500 fois dans le corpus.

```
dfm_trim<-dfm_trim(dfm, max_termfreq = 500)

textstat_frequency(dfm_trim, n=20)
```

```
      feature frequency rank docfreq group
1     qualité       487    1     447   all
2        j'ai       382    2     289   all
3     oiseaux       379    3     319   all
4        tout       375    4     347   all
5        reçu       362    5     332   all
6       colis       360    6     313   all
7  rapidement       356    7     343   all
8     service       351    8     325   all
9        prix       327    9     307   all
10 satisfaite       327    9     301   all
11      super       326   11     294   all
12   conforme       326   11     307   all
13       rien       317   13     299   all
14      bonne       293   14     277   all
15       plus       292   15     254   all
16       tres       278   16     216   all
17   toujours       274   17     236   all
18      mania       256   18     228   all
19      envoi       239   19     231   all
20    sérieux       232   20     220   all
```

```
textplot_wordcloud(dfm_trim, max_words = 100, color = rev(brewer.pal(10, "Set2")))
```

```
Warning in brewer.pal(10, "Set2"): n too large, allowed maximum for palette Set2 is 8
Returning the palette you asked for with that many colors
```


```
display.brewer.all()
```

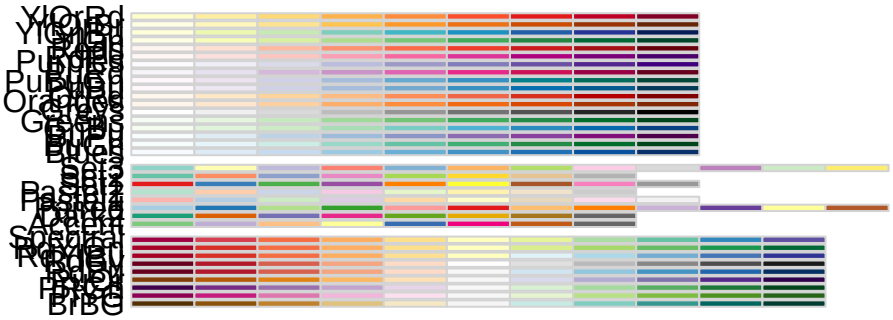

Une autre manière de s'y prendre est d'éliminer directement les termes que l'on ne veut pas voir apparaître.

```
textstat_frequency(dfm,n=20)
```

```
      feature frequency rank docfreq group
1        très      1996    1    1529   all
2      rapide      1659    2    1569   all
3     produit      1414    3    1243   all
4   livraison      1412    4    1299   all
5    commande      1238    5    1030   all
6        bien       920    6     803   all
7        site       793    7     686   all
8           a       706    8     566   all
9         bon       639    9     575   all
10      merci       553   10     529   all
11 recommande       553   10     534   all
12    parfait       522   12     474   all
13    qualité       487   13     447   all
14       j'ai       382   14     289   all
15    oiseaux       379   15     319   all
16       tout       375   16     347   all
17       reçu       362   17     332   all
18      colis       360   18     313   all
19 rapidement       356   19     343   all
20    service       351   20     325   all
```

```
rem<-c("très","rapide","produit","livraison", "commande", "bien", "site", "a", "bon", "merci

dfm_rem<-dfm_remove(dfm, rem)
textstat_frequency(dfm_rem, n=20)
```

```
      feature frequency rank docfreq group
1     qualité       487    1     447   all
2     oiseaux       379    2     319   all
3        tout       375    3     347   all
4        reçu       362    4     332   all
5       colis       360    5     313   all
6  rapidement       356    6     343   all
7     service       351    7     325   all
8        prix       327    8     307   all
9  satisfaite       327    8     301   all
10      super       326   10     294   all
11   conforme       326   10     307   all
```

12	rien	317	12	299	all
13	bonne	293	13	277	all
14	plus	292	14	254	all
15	toujours	274	15	236	all
16	mania	256	16	228	all
17	envoi	239	17	231	all
18	sérieux	232	18	220	all
19	choix	222	19	205	all
20	satisfait	220	20	205	all

6 La loi de Zipf

Vérifions la proposition de la loi de Zipf, selon laquelle la fréquence d'apparition d'un terme est inversement proportionnel à son rang.

```
zipf<-textstat_frequency(dfm)
ggplot(zipf, aes(rank, frequency))+
  geom_line(color="blue")+
  geom_point(color="darkgreen")+
   scale_x_log10() +
   scale_y_log10()+
  theme_light()+
  labs(title = "Observation de la loi de Zipf",x="log (rang)",y="log (fréquence)")
```

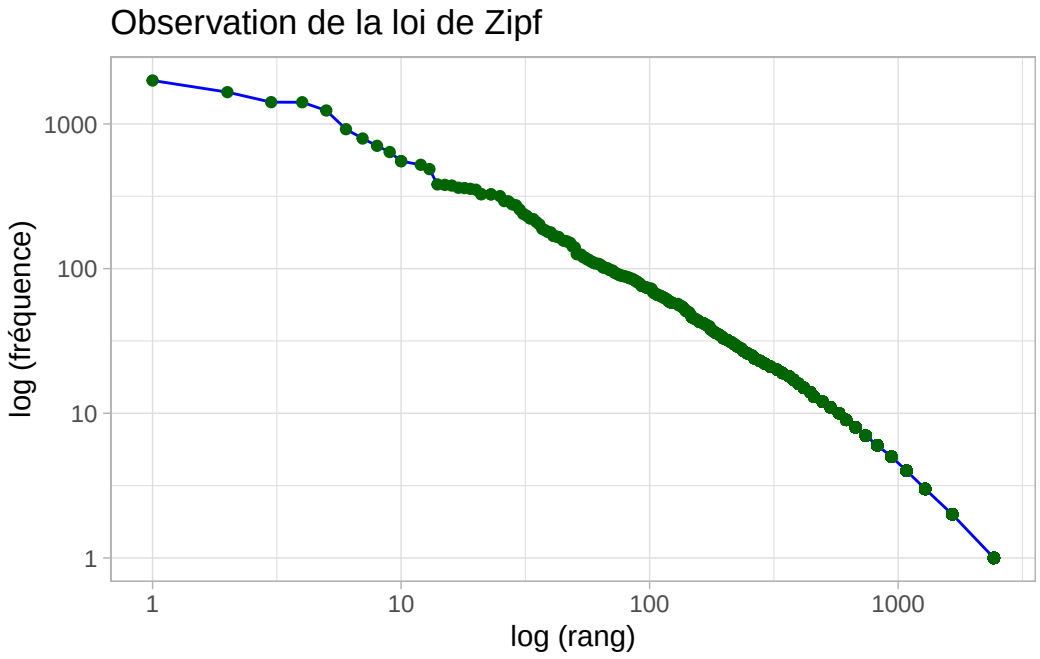

7 Mesures de fréquence

On s'est pour l'instant intéressé uniquement aux termes les plus fréquents dans un corpus. On a vu comment éliminer les termes trop fréquents pour qu'ils nous apportent de l'information. Pour l'analyse de topics, il nous faut prendre un autre angle d'attaque : afin de détecter les sujets abordés dans un corpus, on ne peut se contenter d'observer les mots les plus fréquents, il faut s'intéresser aux termes dont la fréquence dans l'ensemble du corpus est faible, mais qui contribuent fortement à différencier les éléments du corpus entre eux (les documents). On utilise pour cela une mesure de fréquence pondérée : la *tf-idf* pour *term frequency - inverse document frequency* qui permet d'accorder plus de poids aux termes les plus discriminants du corpus. $tf-idf = \frac{occurrence\ du\ mot\ dans\ le\ document}{nombre\ de\ mots\ dans\ le\ document} * log(\frac{nombre\ de\ documents\ dans\ le\ corpus}{nombre\ de\ documents\ dans\ lequel\ le\ mot\ apparait})$

7.1 Pondération tf-idf

On commence par reprendre nos manipulations précédentes : création de corpus, élimination des stopwords, constitution de bi- ou tri- grammes. On applique ensuite la pondération tf-idf.

```
dfmtfidf<-dfm_tfidf(dfm)

dfmtfidf
```

```
Document-feature matrix of: 4,388 documents, 5,429 features (99.81% sparse) and 8 docvars.
       features
docs       comme toujours    super  service  changez     rien     sauf     peut
  text1 1.406738 1.269355 1.173919 1.130383 3.040207 1.166595 2.320047 1.926263
  text2 0        1.269355 2.347839 0        0        0        0        0
  text3 0        0        0        0        0        0        0        0
  text4 0        0        0        0        0        0        0        0
  text5 0        0        0        0        0        0        0        0
  text6 0        0        0        0        0        0        0        0
       features
docs        être       là
  text1 1.961025 2.320047
  text2 0        2.320047
  text3 0        0
```

```
  text4 0        0
  text5 0        0
  text6 0        0
[ reached max_ndoc ... 4,382 more documents, reached max_nfeat ... 5,419 more features ]
```

```r
#Représentations graphiques
textplot_wordcloud(dfm, max_words = 200)
```


```r
textplot_wordcloud(dfmtfidf, max_words = 200)
```


```
#On filtre les mots trop fréquents

dfm_trim<-dfm_trim(dfm, max_termfreq = 500)

dfmtfidf_trim<-dfm_tfidf(dfm_trim)

textplot_wordcloud(dfm_trim, max_words = 200)
```


```
textplot_wordcloud(dfmtfidf_trim, max_words = 200, color = brewer.pal(6, "Set2"))
```

```
display.brewer.all()
```

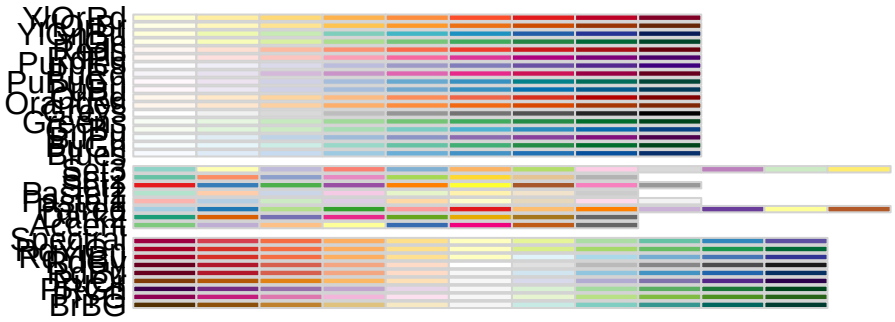

8 Comprendre le sens des termes

On peut visualiser un ou plusieurs termes dans leur contexte, afin d'avoir une meilleure compréhension de leur sens. Pour cela on utilise la fonction "kwic" pour key word in context, à partir de l'objet tokens :

```
head(kwic(tok,"livraison",window = 3))
```

```
Keyword-in-context with 6 matches.
  [text2, 12] revanche n'arrive cliquer | livraison |
  [text3, 13]    depuis conseil jusqu'à | livraison |
  [text5, 36]  perfection puisque délai | livraison |
  [text8, 14]    a entière satisfaction | livraison |
  [text14, 1]                           | Livraison |
 [text15, 21]         trouve peut frais | livraison |

 adresse toujours là
 produit recommande vivement
 Espagne depuis France
 aussi a rapide
 rapide soignée Bons
 élevé
```

```
# kwic(tok,"livraison",window = 3)

head(kwic(tok, c("commande", "recommande"),window = 3))
```

```
Keyword-in-context with 6 matches.
  [text2, 2]                     délai |  commande  | super rapide délais
  [text2, 6]       super rapide délais |  commande  | super rapide revanche
 [text3, 15] jusqu'à livraison produit | recommande | vivement oiseaux Mania
 [text5, 14]   Food regardant dernière |  commande  | j'avais faite France
  [text7, 5]       semaines j'ai passé |  commande  | toujours livré étoile
  [text8, 9]       j'ai néanmoins fait |  commande  | difficulté a entière
```

```
head(kwic(tok,"perroquet",window = 3))
```

```
Keyword-in-context with 6 matches.
  [text5, 51]    d'avoir trouvé solution | perroquet |
  [text18, 8]        compétent sers site | perroquet |
 [text22, 18]         convient tout fait | perroquet |
  [text34, 6] treats granulés compressés | Perroquet |
 [text37, 10]        choix produit petit | perroquet |
  [text39, 2]               Alimentation | perroquet |

 afin qu'il puisse
   Excellent rapide
 très heureux aussi
 Gris Gabon très
 n'hésiterai refaire commandes
 commande depuis quelques
```

```
head(kwic(tok,"prix",window=10))
```

```
Keyword-in-context with 6 matches.
  [text14, 6]
 [text15, 15]
 [text26, 23]
 [text28, 12]
 [text31, 77]
  [text32, 7]

                                                 Livraison rapide soignée Bons produit
            rapide satisfait commander cher oiseaux mania car Besançon trouve produit
 beaucoup choix graines friandises accessoires commande a livrée rapidement encombres
      harnais reçus déplore juste l’emballage spartiate arrivé moitié déchiré rapport
                          flacons 57gr chacun ça fait peut chère Mondial relay offre
                                        Livraison rapide Bons produit bien emballé

 | prix | raisonnables
 | Prix | très attractif trouve peut frais livraison élevé
 | Prix | intéressant
 | prix | vente c’est peu léger surtout harnais
 | prix | bien plus raisonnable Bien cordialement
 | prix | raisonnables
```

9 Analyse du sentiment

```
knitr::opts_chunk$set(
  echo = TRUE,
  message = FALSE,
  warning = FALSE)
library(readxl)
library(tidyverse)
library(quanteda)
library(quanteda.textstats)
library(quanteda.textplots)
library(RColorBrewer)
display.brewer.all()
```

10 Les données

```
data <- read_csv("data/data_trustpilot_oiseaux.csv")
```

11 *Sentiment analysis*

On va réaliser une analyse du sentiment du corpus. Pour cela, on utilise le dictionnaire des sentiments et émotions NRC, car il est disponible dans 40 langues, dont le français. Il existe d'autres dictionnaires de sentiments (positif vs négatif), par exemple AFINN ou BING, ainsi que des dictionnaires thématiques (LIWC par exemple), mais ils sont en anglais ou payants, donc utilisables pour des corpus en anglais ou lorsqu'on dispose d'un budget. Les dernières évolutions du traitement en langage naturel des IA (transformers et autres, dont ChatGPT est un exemple), permettent d'autres approches très pertinentes, en utilisant le *machine learning*, mais cela va au-delà des objectifs de ce cours.

Ici, on utilise le dictionnaire NRC à travers le package *syuzhet*. La fonction *get_nrc_sentiment* prend en entrée un vecteur de type caractère.

```
library(syuzhet)

# d<-get_nrc_sentiment(data$comments, language = "french")
# write_rds(d, "sentiment_trustpilot_oiseaux.rds")

d<-read_rds("data/sentiment_trustpilot_oiseaux.rds")
summary(d, digits=1)
```

```
     anger       anticipation      disgust         fear           joy
 Min.   :0.0   Min.   : 0.0   Min.   :0.0   Min.   :0.0   Min.   :0.0
 1st Qu.:0.0   1st Qu.: 0.0   1st Qu.:0.0   1st Qu.:0.0   1st Qu.:0.0
 Median :0.0   Median : 1.0   Median :0.0   Median :0.0   Median :0.0
 Mean   :0.1   Mean   : 0.9   Mean   :0.1   Mean   :0.1   Mean   :0.6
 3rd Qu.:0.0   3rd Qu.: 1.0   3rd Qu.:0.0   3rd Qu.:0.0   3rd Qu.:1.0
 Max.   :7.0   Max.   :10.0   Max.   :7.0   Max.   :6.0   Max.   :6.0
    sadness       surprise       trust        negative       positive
 Min.   :0.0   Min.   :0.0   Min.   :0.0   Min.   : 0.0   Min.   : 0
 1st Qu.:0.0   1st Qu.:0.0   1st Qu.:0.0   1st Qu.: 0.0   1st Qu.: 1
 Median :0.0   Median :1.0   Median :1.0   Median : 0.0   Median : 2
 Mean   :0.2   Mean   :0.7   Mean   :0.9   Mean   : 0.4   Mean   : 2
 3rd Qu.:0.0   3rd Qu.:1.0   3rd Qu.:1.0   3rd Qu.: 0.0   3rd Qu.: 3
 Max.   :7.0   Max.   :5.0   Max.   :8.0   Max.   :12.0   Max.   :14
```

```
data<-cbind(data,d)

data[600,8:17]
```

```
    anger anticipation disgust fear joy sadness surprise trust negative
600     0            1       0    1   1       0        1     1        0
    positive
600        1
```

```
data[600,"comments"]
```

```
[1] "Commande reçu dans les temps pas de surprise. Très bon site"
```

Le dictionnaire comprend 10 variables, 8 émotions et 2 sentiments. Pour représenter les données, nous avons besoin de les transformer.

```
e<-d%>%
  pivot_longer(everything(),names_to = "sentiment", values_to = "nb")

ggplot(e, aes(sentiment, nb))+
  geom_col(aes(fill=sentiment),show.legend = FALSE)+
  theme_minimal()+
  coord_flip()
```

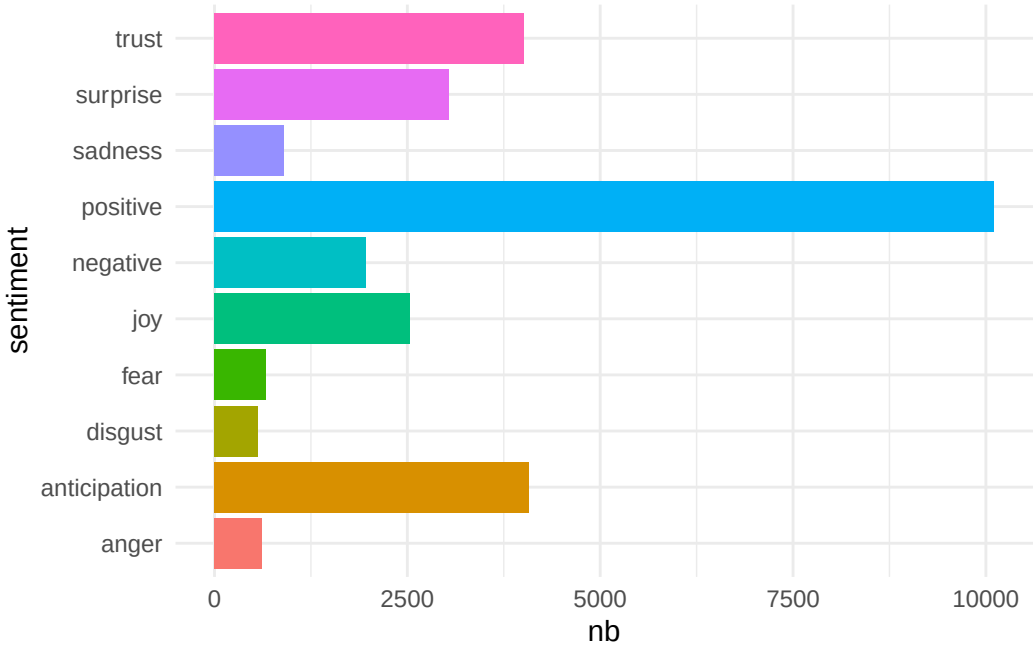

11.1 Les sentiments

Intéressons-nous d'abord aux sentiments :

```
sent<-d%>%
  select(positive,negative)%>%
  pivot_longer(everything(), names_to = "sentiment", values_to = "nb")%>%
  summarise(nb=sum(nb), .by = sentiment)%>%
  mutate(prop=nb/sum(nb))

ggplot(data=sent,  aes(x=sentiment, y=prop)) +
  geom_bar(stat="identity", aes(fill=sentiment), show.legend = FALSE)+
  scale_y_continuous(labels=scales::percent) +
  labs(title = "Répartition des sentiments dans le corpus Oiseaux Mania",caption = "Données
  scale_fill_manual(values=c("red", "lightgreen"))+
  theme_light()
```

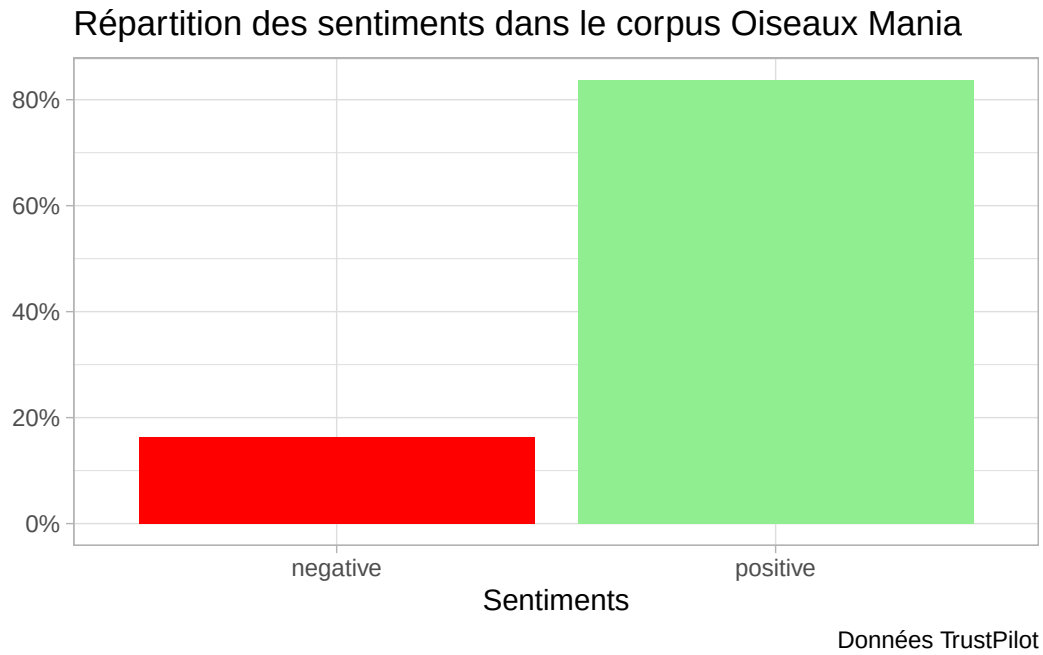

Le corpus est très largement positif, ce qui n'est pas étonnant. On peut aussi créer d'autres indicateurs, comme la valence (différence positif-négatif) ou l'expressivité (somme de positif+négatif).

Exercice : personnalisez le graphique ci-dessous pour la variable d'expressivité.

```
data<-data%>%
  mutate(nbcar=nchar(comments),
         valence = positive-negative)

ggplot(data = data, aes(x = valence, y= nbcar))+
  geom_point()+
  geom_smooth()+
  labs(title="Indicateur de valence", subtitle = "en fonction du nombre de caractères", capti
  theme_minimal()
```

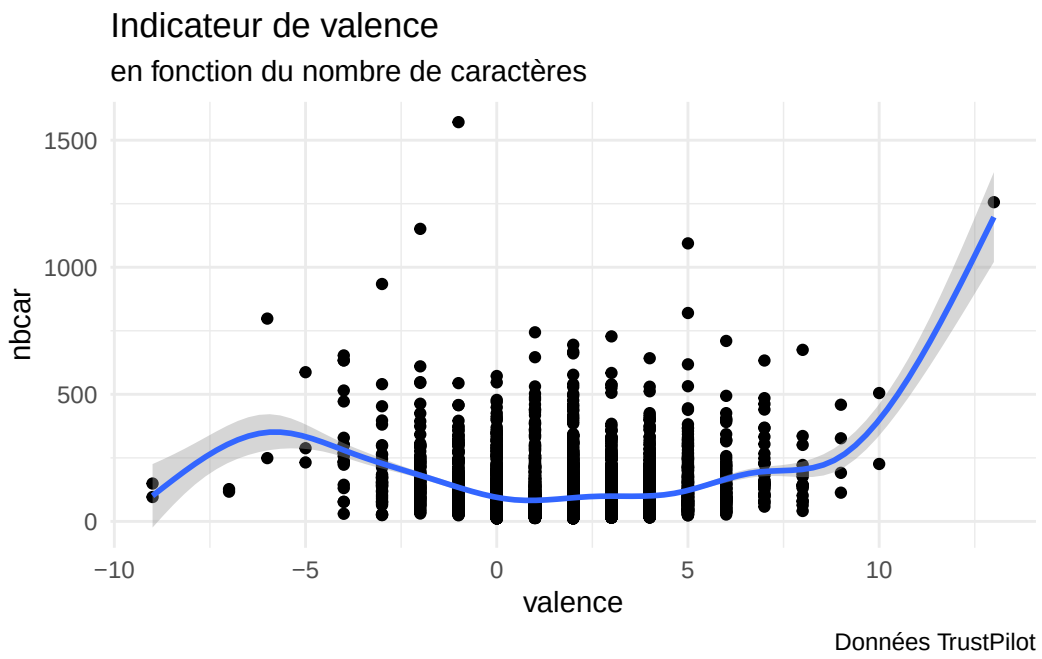


```
data<-data%>%
  mutate(nbcar=nchar(comments),
         expressivité = positive+negative)

ggplot(data = data, aes(x = expressivité, y= nbcar))+
  geom_point()+
  geom_smooth()+
  labs(title="Indicateur d'expressivité", subtitle = "en fonction du nombre de caractères", c
  theme_minimal()
```

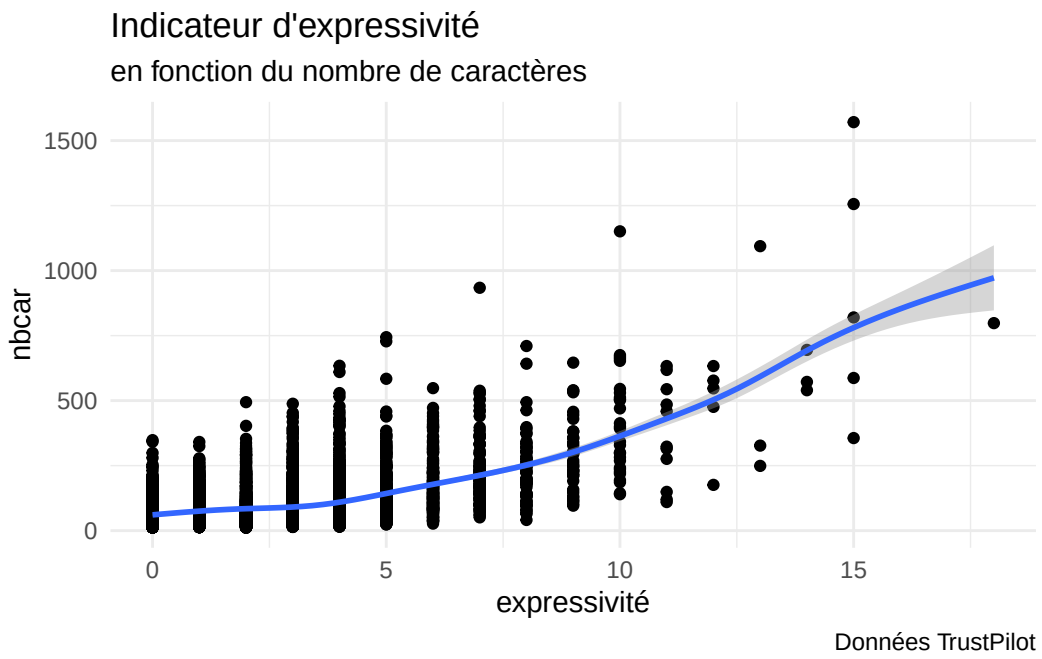

11.2 Les émotions

Regardons maintenant ce qu'il en est de la répartition des émotions :

```
#On crée d'abord une palette pour les émotions
emocol<-c("yellow","chartreuse","olivedrab3","green4","royalblue3","purple3","red3","orangere



emo<-d%>%
  select(-positive, -negative)%>% #On récupère les émotions
  pivot_longer(everything(), names_to = "emotion", values_to = "nb")#On transforme le tableau

emo2<-emo%>%
  summarise(nb=sum(nb), .by = emotion)%>%
  mutate(prop=nb/sum(nb),
         emotion=factor(emotion, ordered = TRUE,levels = c("joy","trust","fear","surprise",'

#On crée un graphique circulaire
ggplot(data=emo2,  aes(x=emotion, y=prop, colour=emotion)) +
  geom_bar(stat="identity", aes(fill=emotion), show.legend = FALSE)+
  scale_y_continuous(labels=scales::percent)+
```

```
  labs(title="Distribution des émotions \n dans le corpus Oiseaux Mania", caption="Données Tr
  coord_polar()+
  scale_color_manual(values=emocol)+ scale_fill_manual(values=emocol)+
  theme_minimal()
```

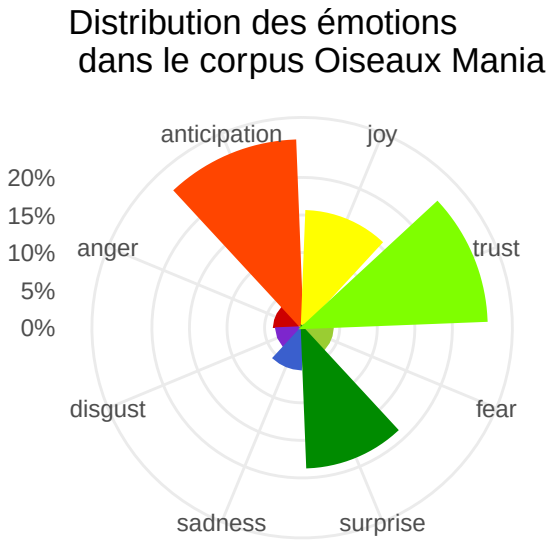


```
#On regarde la répartition des émotions dans le corpus :

ggplot(emo, aes(x=emotion, y=nb))+
  geom_violin(aes(fill=emotion), alpha=0.7,adjust = 2)+
  theme_minimal()+ scale_fill_manual(values=emocol)+
  scale_x_discrete(labels=NULL)
```

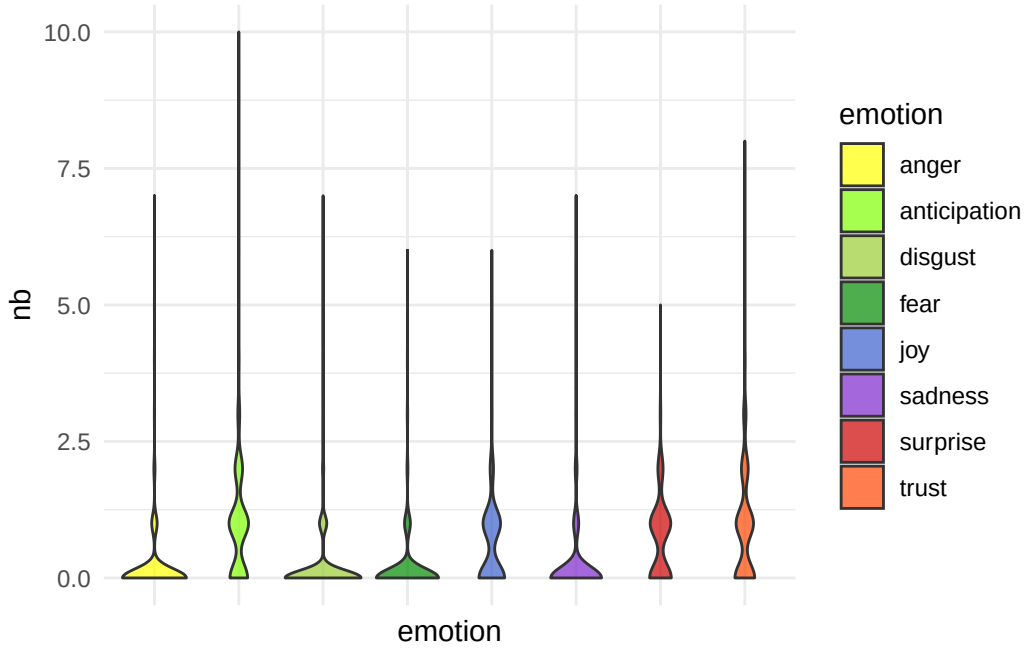


```
ggplot(emo, aes(x=emotion, y=nb))+
  geom_boxplot(aes(fill=emotion,), alpha=0.7,adjust = 2, show.legend = FALSE)+
  theme_minimal()+ scale_fill_manual(values=emocol)
```

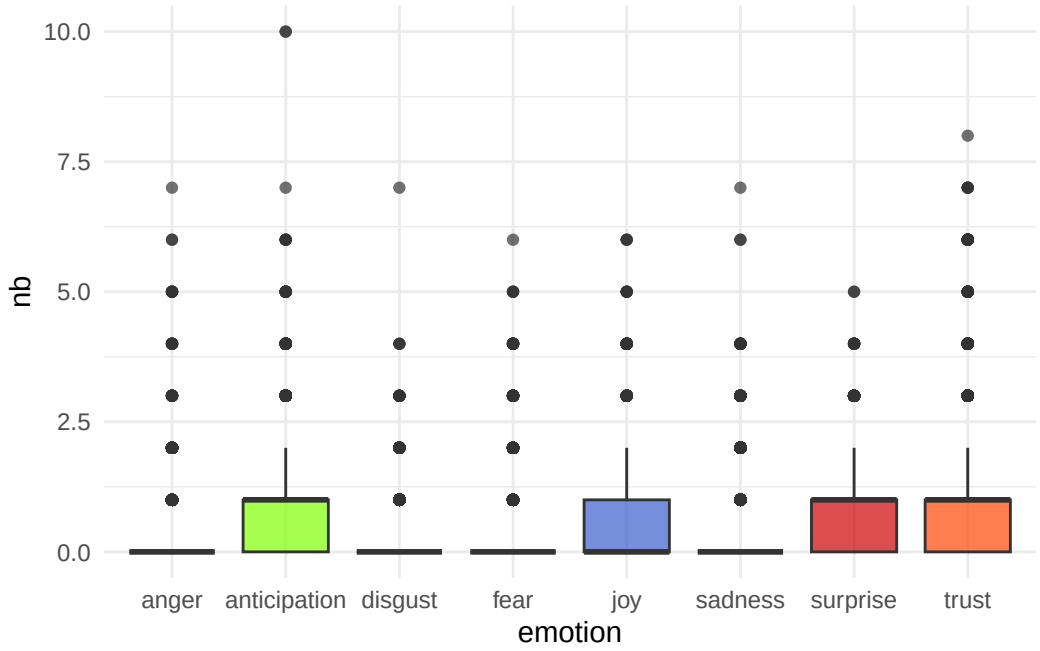

12 Évolution du corpus dans le temps

On va regarder comment les sentiments évoluent dans le temps. On doit tout d'abord créer une variable temporel dans notre jeu de données. Nous en avons déjà une, qui indique la date et l'heure à laquelle le commentaire a été posté. Nous allons la transformer pour regrouper les commentaires en fonction de l'année (on peut le faire pour les jours, les mois, les minutes, ...).

```
data%>%group_by(year)%>%summarise('nb com'=n())
```

```
# A tibble: 11 x 2
    year `nb com`
   <dbl>    <int>
 1  2013      125
 2  2014      209
 3  2015      249
 4  2016      171
 5  2017      324
 6  2018      341
 7  2019      375
 8  2020      735
 9  2021      853
10  2022      623
11  2023      383
```

Regardons maintenant comment évolue les sentiments dans le temps :

```
#les émotions
##mise en forme des données
gen_sent<-data%>%
  mutate(year=as.factor(year))%>%
  group_by(year)%>%
  summarise(across(7:14,~mean(.x, na.rm = T)))%>%
  na.exclude()%>%
  pivot_longer(-year, names_to = "emotion", values_to = "mean")%>%
  mutate(emotion=factor(emotion, ordered = TRUE,levels = c("joy","trust","fear","surprise","s
```

```r
##graphique
ggplot(gen_sent,aes(x=year, y=mean,group=emotion)) +
  geom_line(aes(color=emotion), linewidth=0.5) +
  theme_minimal()+
  scale_color_manual(values = emocol)
```

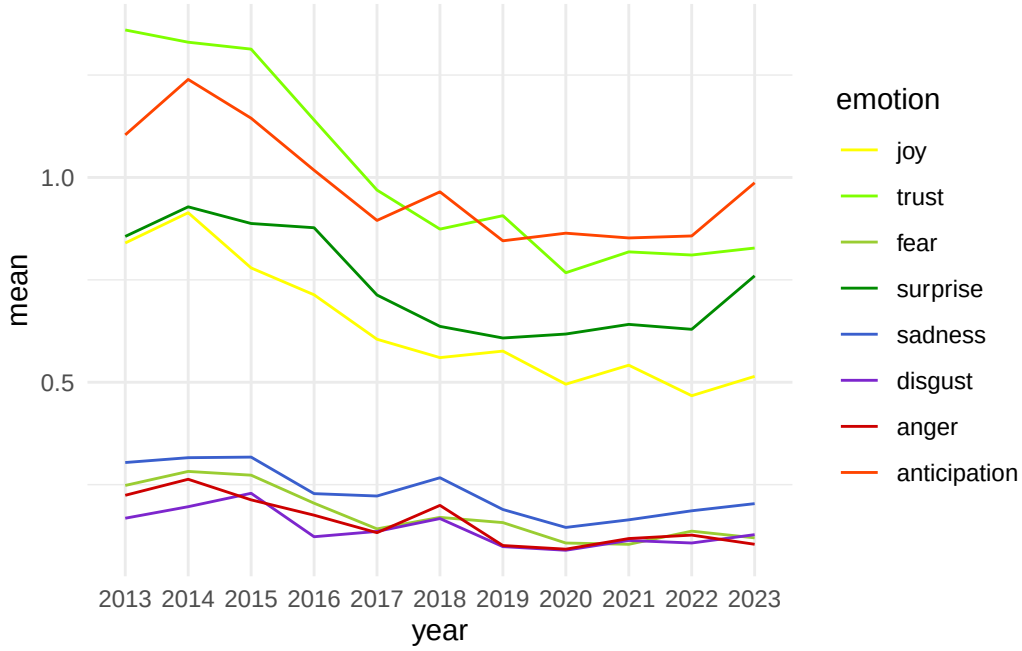


```r
#les sentiments
##mise en forme des données
gen_sent2<-data%>%
  mutate(year=as.factor(year))%>%
  group_by(year)%>%
  summarise(across(c(positive, negative),~mean(.x, na.rm = T)))%>%
  na.exclude()%>%
  pivot_longer(-year, names_to = "sentiment",values_to = "mean")

##graphique
ggplot(gen_sent2,aes(x=year, y=mean,group=sentiment)) +
  geom_line(aes(color=sentiment), linewidth=0.5) +
  theme_minimal()+
  scale_color_manual(values = c("red","lightgreen"))
```

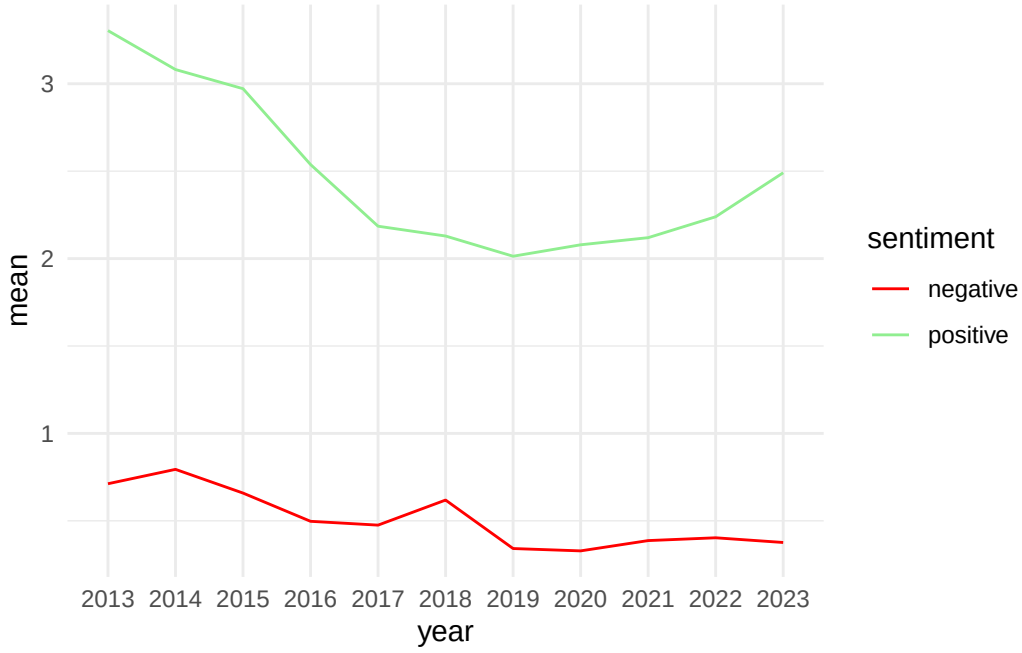

Maintenant, on va s'intéresser aux mots.

13 Nuage de mots comparés

13.1 En fonction des années

On refait les manipulations préliminaires :

```
data<-data%>%
  mutate(year2=case_when(year<2017~"2013-2016",
                         year %in% c(2017:2019)~"2017-2019",
                         .default=as.character(year)))

corpus_oiseaux<-corpus(data, text_field = "comments")

tok<-tokens(corpus_oiseaux, remove_punct = TRUE, remove_numbers = TRUE, remove_symbols = TRU
  tokens_remove(stopwords("fr"))

dfm<-dfm(tok)
```

Comparons les mots en fonction des années :

```
dfmgp<-dfm_group(dfm, groups = year2)
dfmgp
```

```
Document-feature matrix of: 6 documents, 5,392 features (66.69% sparse) and 1 docvar.
           features
docs        comme toujours super service changez rien sauf peut être là
  2013-2016    38       26    93      58       0   71    6   17    9  8
  2017-2019    32       61    74      78       0   76    5   13   24  4
  2020         27       38    42      65       0   51    0    5    6  1
  2021         35       49    49      64       2   62    8   11   11  2
  2022         36       49    46      59       0   36    0    4    3  3
  2023         16       51    22      27       2   21    3    6    3  4
[ reached max_nfeat ... 5,382 more features ]
```

```
#On peut aussi passer la fonction directement en transformant en dfm avec l'option groups : c

textplot_wordcloud(dfmgp, comparison=TRUE, max_words = 200)
```

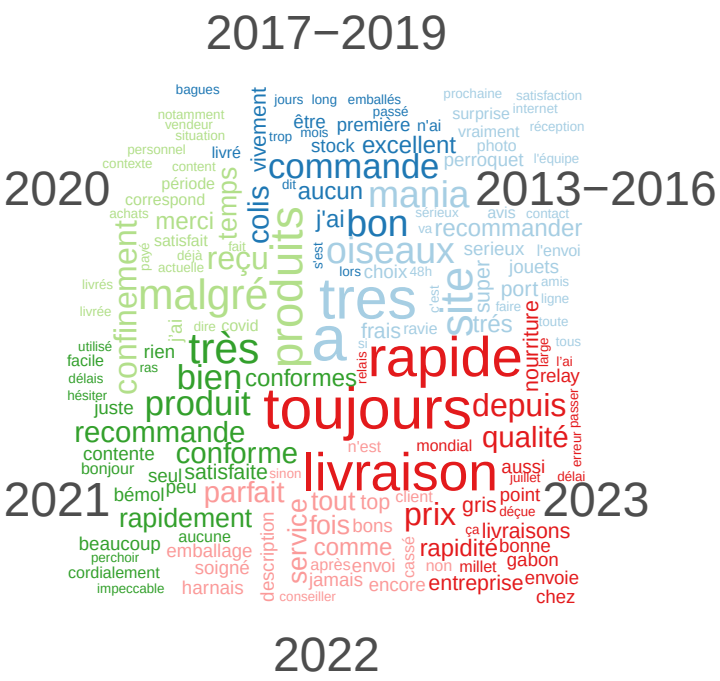

13.2 En fonction des sentiments

Pour comparer en fonction des sentiments, il faut accéder au dictionnaire NRC (en français) (il y a des fonctions simplifiées pour les dictionnaires en anglais) :

```
dic_nrc<-read_xlsx("NRCfr.xlsx")%>%
  pivot_longer(-word,names_to = "sentiment", values_to="value")%>%
  filter(value==1, word!="NO TRANSLATION")%>%
  select(-value)

sent_term<-convert(dfm,to="data.frame")%>%
  select(-doc_id)%>%
  pivot_longer(everything(), names_to="word", values_to="value")%>%
  filter(value!=0)%>%
  summarise(value=sum(value), .by=word)%>%
  inner_join(dic_nrc)%>%
  slice_max(n=10, by=sentiment, order_by = value, with_ties=F)
```

```
ggplot(sent_term, aes(reorder(word, value), value, fill = sentiment)) +
  geom_col(show.legend = FALSE) +
  facet_wrap(~sentiment, scales = "free_y") +
  labs(y = "Contribution to sentiment",
       x = NULL) +
  coord_flip()+
  theme_minimal()
```

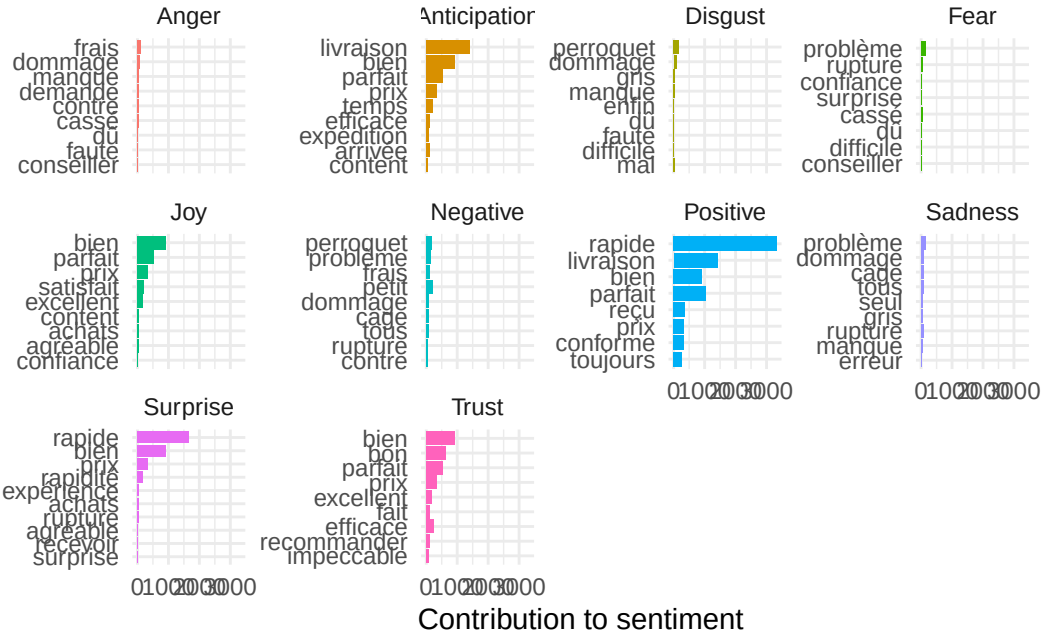

Part II

Niveau 2 : Approfondissements

14 Annotations et dépendances syntaxiques

```
library(readxl)
library(tidyverse)
library(quanteda)
library(quanteda.textstats)
library(quanteda.textplots)
library(RColorBrewer)
display.brewer.all()
```

15 Les données

```
data <- read_csv("data/data_trustpilot_oiseaux.csv")
```

```
Rows: 4388 Columns: 7
-- Column specification --------------------------------------------------------
Delimiter: ","
chr (4): auteur, date, month, comments
dbl (3): id, year, note

i Use `spec()` to retrieve the full column specification for this data.
i Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

```
data$nb_caractere<-nchar(data$comments) #on compte le nombre de caractère de chaque commentai
summary(data$nb_caractere)
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   12.0    41.0    74.0   104.3   130.0  1571.0
```

```
mean(data$nb_caractere)
```

```
[1] 104.2974
```

```
median(data$nb_caractere)
```

```
[1] 74
```

```
round(mean(data$nb_caractere),1)
```

```
[1] 104.3
```

```r
moy<-round(mean(na.omit(data$nb_caractere)), 1)

ggplot(data)+
  geom_boxplot(aes(nb_caractere))+
  geom_text(aes(x=500, y=0.2,label=paste("Moyenne :",moy)))+
  coord_flip()+
  scale_y_continuous(NULL, breaks = NULL)+
  theme_minimal()
```

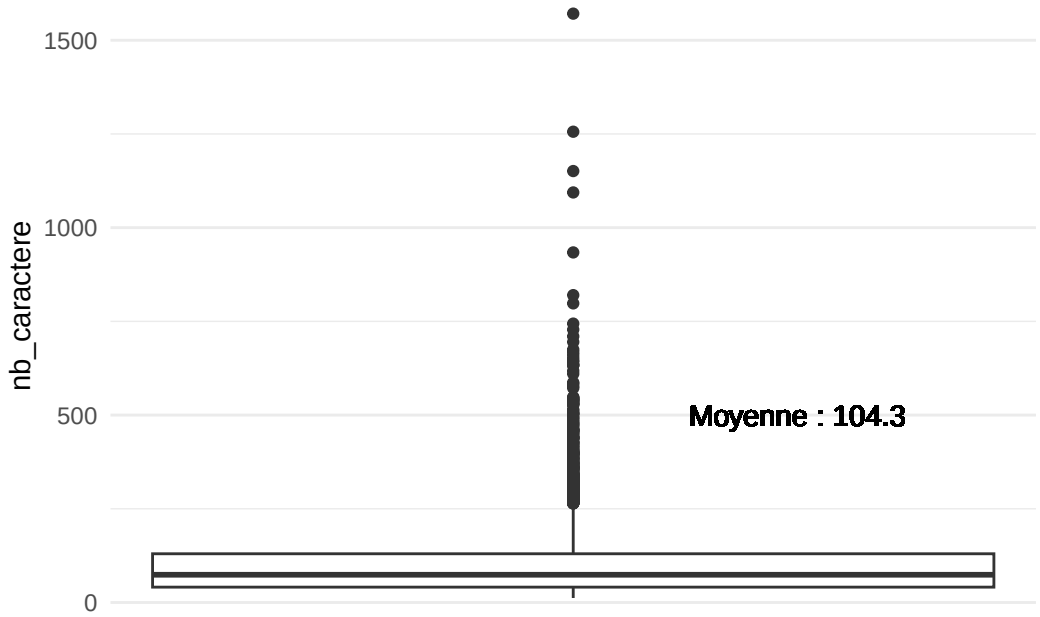

16 Les traitements préliminaires

On reprend ce qu'on a fait au cours dernier, sans éliminer les termes trop fréquents :

```
corpus_oiseaux<-corpus(data, text_field = "comments")

tok<-tokens(corpus_oiseaux, remove_punct = TRUE, remove_numbers = TRUE, remove_symbols = TRU
  tokens_remove(stopwords("fr"))

dfm<-dfm(tok)
```

17 Co-occurrences

On va maintenant constituer des bi-grammes basés sur de nombreuses co-occurrences entre les termes :

```
# textstat_collocations(tok)

head(textstat_collocations(tok), 5)
```

```
       collocation count count_nested length   lambda        z
1 livraison rapide   612            0      2 3.587755 56.29325
2    oiseaux mania   194            0      2 7.111407 38.50542
3         très bon   291            0      2 3.325458 37.28183
4        très bien   332            0      2 2.763473 37.07693
5    bonne qualité   116            0      2 4.440036 33.65412
```

```
tail(textstat_collocations(tok),10)
```

```
            collocation count count_nested length    lambda         z
4046          bien bien     3            0      2 -1.601302 -2.983435
4047 livraison produits     4            0      2 -1.539254 -3.248433
4048        site rapide     7            0      2 -1.205217 -3.274181
4049  commande commande     8            0      2 -1.154362 -3.338450
4050        bien rapide    10            0      2 -1.111673 -3.567851
4051    produits rapide     2            0      2 -2.293296 -3.616176
4052 livraison commande     9            0      2 -1.233460 -3.770310
4053             très a     2            0      2 -2.581564 -4.071675
4054      rapide rapide     4            0      2 -2.401230 -5.077424
4055          très très    22            0      2 -1.110720 -5.196198
```

```
colloc<-textstat_collocations(tok, min_count = 10, tolower = TRUE)
head(colloc,10)
```

```
        collocation count count_nested length   lambda        z
```

```
1  livraison rapide   612            0      2 3.587755 56.29325
2     oiseaux mania   194            0      2 7.111407 38.50542
3          très bon   291            0      2 3.325458 37.28183
4         très bien   332            0      2 2.763473 37.07693
5     bonne qualité   116            0      2 4.440036 33.65412
6         rien dire    93            0      2 5.576935 32.54402
7       bon produit   146            0      2 3.412030 32.15574
8      envoi rapide   137            0      2 3.741715 27.61231
9  produit conforme    94            0      2 3.613662 27.52989
10  très satisfaite   154            0      2 3.288031 27.11619
```

```
tail(colloc,10)
```

```
          collocation count count_nested length     lambda         z
356   livraison merci    10            0      2 -0.4024193 -1.285159
357 commande produits    11            0      2 -0.3922655 -1.311659
358       rapide site    13            0      2 -0.4424632 -1.601325
359  rapide livraison    23            0      2 -0.3478837 -1.653038
360     bien commande    11            0      2 -0.5705858 -1.910948
361          rapide a    10            0      2 -0.6915725 -2.214619
362          a rapide    10            0      2 -0.8863541 -2.840453
363   commande rapide    21            0      2 -0.6532274 -2.978690
364       bien rapide    10            0      2 -1.1116732 -3.567851
365         très très    22            0      2 -1.1107203 -5.196198
```

```
tok_cooc<-tokens_compound(tok, pattern = colloc[colloc$z>6.97,],join = TRUE)

tok["text400"]
```

```
Tokens consisting of 1 document and 7 docvars.
text400 :
[1] "Excellent" "service"   "livraison" "rapide"
```

```
tok_cooc["text400"]
```

```
Tokens consisting of 1 document and 7 docvars.
text400 :
[1] "Excellent_service" "livraison_rapide"
```

Analyse de fréquence et représentation graphique :

```r
dfm_cooc<-dfm(tok_cooc)

dfm_cooc2<-dfm_trim(dfm_cooc, max_termfreq = 170)

head(textstat_frequency(dfm_cooc2),20)
```

```
           feature frequency rank docfreq group
1             prix       169    1     160   all
2          service       165    2     154   all
3        perroquet       165    2     150   all
4          oiseaux       165    2     145   all
5              top       163    5     149   all
6          qualité       160    6     153   all
7    oiseaux_mania       142    7     129   all
8       rapidement       139    8     137   all
9             tres       127    9     107   all
10        articles       124   10     115   all
11        rapidité       124   10     117   all
12            reçu       122   12     114   all
13         sérieux       121   13     114   all
14             car       120   14     111   all
15           temps       120   14     115   all
16       satisfait       115   16     108   all
17        problème       114   17     102   all
18           comme       114   17     108   all
19 très_satisfaite       111   19     107   all
20         graines       107   20      87   all
```

```r
textplot_wordcloud(dfm_cooc2, max_words = 200, color = brewer.pal(6, "Set2"))
```


```
tok_cooc<-tokens_replace(tok_cooc, c("très_rapidement","très_satisfait"), c("très_rapide","tr

dfm_cooc<-dfm(tok_cooc)
textstat_frequency(dfm_cooc, n=25)
```

```
            feature frequency rank docfreq group
1          commande       715    1     620   all
2                 a       502    2     412   all
3         livraison       474    3     432   all
4              site       401    4     359   all
5  livraison_rapide       389    5     381   all
6             merci       380    6     368   all
7           parfait       361    7     334   all
8              très       349    8     298   all
9           produit       331    9     294   all
10           rapide       328   10     310   all
11         produits       321   11     292   all
12       recommande       320   12     313   all
13             plus       292   13     254   all
14             bien       280   14     251   all
15        très_bien       256   15     236   all
16            super       252   16     232   all
```

```
17              tout       245   17      224   all
18              j'ai       234   18      189   all
19            colis        207   19      176   all
20  très_satisfaite        202   20      195   all
21            c'est        196   21      168   all
22         toujours        188   22      163   all
23      très_rapide        174   23      168   all
24             prix        169   24      160   all
25          service        165   25      154   all
```

```
dfm_cooc2<-dfm_trim(dfm_cooc, max_termfreq = 175)

textplot_wordcloud(dfm_cooc2, max_words = 100, color = brewer.pal(6, "Set2"))
```

17.1 Représentation en réseau des termes co-occurents

```
#
# fcm_cooc<-fcm(dfm_cooc2)
# fcm_cooc
# topfeatures(fcm_cooc)
```

```
# dim(fcm_cooc)
#
# feat<-names(topfeatures(fcm_cooc, 50))
# fcm_cooc_select<-fcm_select(fcm_cooc, pattern = feat, selection = "keep")
# dim(fcm_cooc_select)
#
# textplot_network(fcm_cooc_select, min_freq = 0.8, edge_color = "red" , edge_alpha = 0.5, ve
#
#
# tpfeat<-tibble(feat=names(topfeatures(fcm_cooc,50)),n=topfeatures(fcm_cooc,50))
# tpfeat<-tpfeat%>%mutate(taille=n/150)
#
# textplot_network(fcm_cooc_select, min_freq = 0.8, edge_color = "red" , edge_alpha = 0.5, ve
#
# textplot_network(fcm_cooc_select, min_freq = 0.8, edge_color = "red" , edge_alpha = 0.5, ve
#
#
#
# textplot_network(fcm_cooc_select, min_freq = 0.8, edge_color = "red" , edge_alpha = 0.5, ve
```

18 Annotations

Pour cette partie, on repart du jeu de données brut.

18.1 Détecter les langues

Dans le cas d'un corpus composé de plusieurs langues (par exemple, un corpus extrait de twitter), il peut être intéressant de filtrer le corpus à partir de la langue. On utilise un algorithme, qui peut être long à exécuter selon la taille du corpus, et qui est plutôt performant : cld3. Il repose sur un réseau de neurones développé par Google

```
library(cld3)

data$langue<-detect_language(data$comments)
# data$langue

data_fr<-data%>%filter(langue=="fr")
```

18.2 POS

```
library(cleanNLP)

# cnlp_init_udpipe(model_name = "french")
#
# annotate<-cnlp_annotate(data$comments, verbose = 100)
# ann_token<-annotate$token
# write_csv2(ann_token, "annotation_oiseaux.csv")
# write_rds(ann_token,"annotation_oiseaux.rds")

ann_token<-read_rds("data/annotation_oiseaux.rds")

head(ann_token%>%filter(upos=="ADJ"|upos=="NOUN"|upos=="VERB"),15)
```

```
# A tibble: 15 x 11
   doc_id   sid tid   token    token_with_ws lemma  upos  xpos  feats tid_source
    <int> <int> <chr> <chr>    <chr>         <chr>  <chr> <chr> <chr> <chr>
 1      1     1 4     super    "super "      super  ADJ   <NA>  Gend~ 5
 2      1     1 5     service  "service"     servi~ NOUN  <NA>  Gend~ 0
 3      1     2 2     changez  "changez "    chang~ VERB  <NA>  Mood~ 0
 4      1     2 5     peut     "peut "       pouvo~ VERB  <NA>  Mood~ 2
 5      1     2 8     cagnotte "cagnotte "   cagnot ADJ   <NA>  Gend~ 9
 6      1     2 9     fidélité "fidélité "   fidél~ NOUN  <NA>  Gend~ 5
 7      1     2 11    est      "est"         être   VERB  <NA>  Mood~ 9
 8      1     2 15    dirais   "dirais "     dir    VERB  <NA>  Mood~ 11
 9      1     2 16    inutile  "inutile "    inuti~ ADJ   <NA>  Gend~ 15
10      2     1 2     délai    "délai "      délai  NOUN  <NA>  Gend~ 0
11      2     1 5     commande "commande "   comma~ NOUN  <NA>  Gend~ 2
12      2     1 7     rapide   "rapide "     rapide ADJ   <NA>  Gend~ 5
13      2     2 2     délais   "délais "     délais NOUN  <NA>  Gend~ 14
14      2     2 6     commande "commande "   comma~ NOUN  <NA>  Gend~ 2
15      2     2 8     rapide   "rapide"      rapide ADJ   <NA>  Gend~ 6
# i 1 more variable: relation <chr>
```

```
ann_token%>%filter(upos=="ADJ"|upos=="NOUN"|upos=="VERB")
```

```
# A tibble: 34,232 x 11
   doc_id   sid tid   token    token_with_ws lemma  upos  xpos  feats tid_source
    <int> <int> <chr> <chr>    <chr>         <chr>  <chr> <chr> <chr> <chr>
 1      1     1 4     super    "super "      super  ADJ   <NA>  Gend~ 5
 2      1     1 5     service  "service"     servi~ NOUN  <NA>  Gend~ 0
 3      1     2 2     changez  "changez "    chang~ VERB  <NA>  Mood~ 0
 4      1     2 5     peut     "peut "       pouvo~ VERB  <NA>  Mood~ 2
 5      1     2 8     cagnotte "cagnotte "   cagnot ADJ   <NA>  Gend~ 9
 6      1     2 9     fidélité "fidélité "   fidél~ NOUN  <NA>  Gend~ 5
 7      1     2 11    est      "est"         être   VERB  <NA>  Mood~ 9
 8      1     2 15    dirais   "dirais "     dir    VERB  <NA>  Mood~ 11
 9      1     2 16    inutile  "inutile "    inuti~ ADJ   <NA>  Gend~ 15
10      2     1 2     délai    "délai "      délai  NOUN  <NA>  Gend~ 0
# i 34,222 more rows
# i 1 more variable: relation <chr>
```

```
g<-ann_token%>%group_by(upos)%>%
  summarise(n=n())%>%
  filter(!is.na(upos))
```

```r
ggplot(g)+
  geom_col(aes(reorder(upos,n),n, fill=n), show.legend = FALSE)+
  scale_fill_fermenter(palette = "PuRd", direction = 1)+
  coord_flip()+
  labs(title = "Fréquence des UPOS", subtitle = "Corpus Oiseaux Mania", caption = "Data Trust
  theme_dark()
```

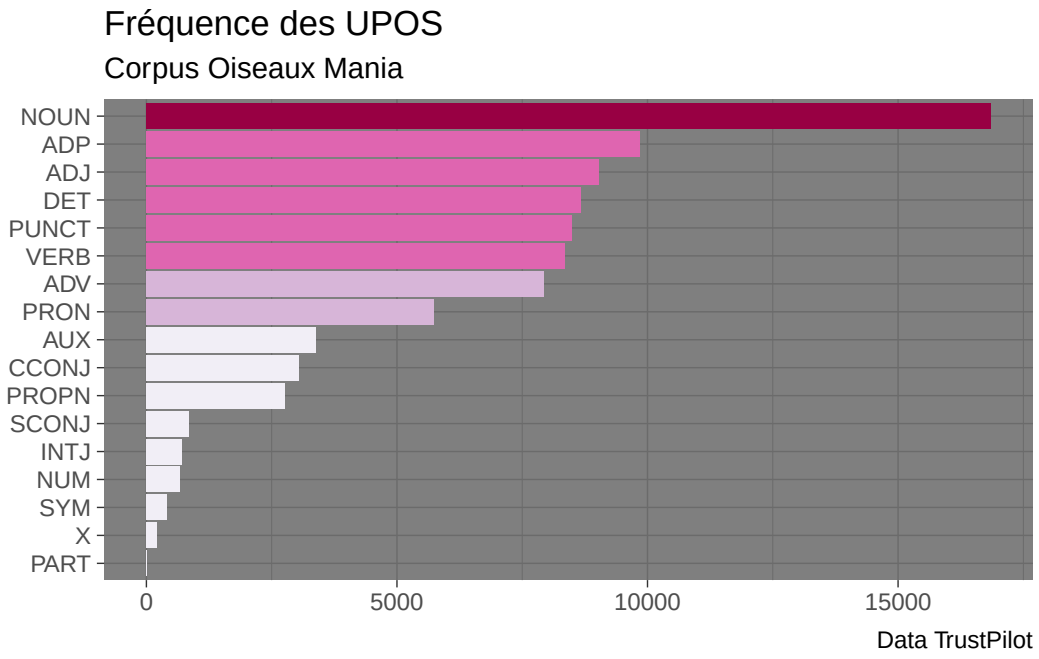

Maintenant, on va s'intéresser à des catégories grammaticales spécifiques :

```r
vocab1<-ann_token%>%
  filter(upos=="NOUN")%>%
  summarise(freq=n(),.by=lemma)%>%
  filter(freq>55)

ggplot(vocab1,aes(x=reorder(lemma,freq),y=freq))+
  geom_bar(stat="identity",fill="lightgreen")+
  coord_flip()+
  theme_minimal()+
  labs(title = "Noms communs les plus fréquents",subtitle = "Corpus Oiseaux Mania", caption="
```

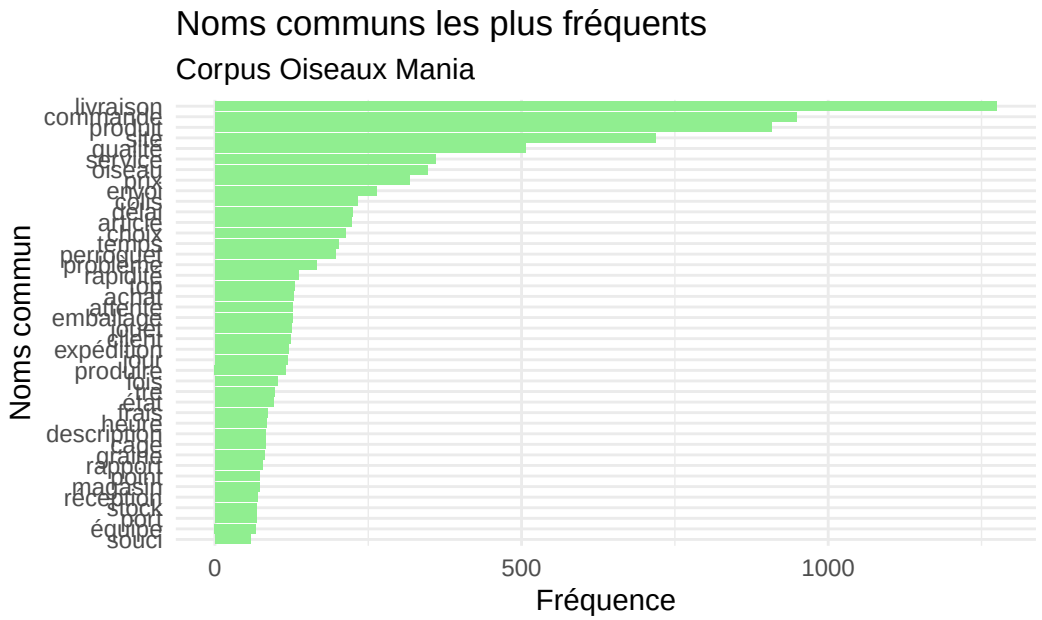


```
vocab1bis<-ann_token%>%
  filter(upos=="ADJ")%>%
  summarise(freq=n(),.by=lemma)%>%
  filter(freq>55)

ggplot(vocab1bis,aes(x=reorder(lemma,freq),y=freq))+
  geom_bar(stat="identity",fill="darkblue")+
  coord_flip()+
  theme_minimal()+
  labs(title = "Adjectifs les plus fréquents",subtitle = "Corpus Oiseaux Mania", caption="Dat
```

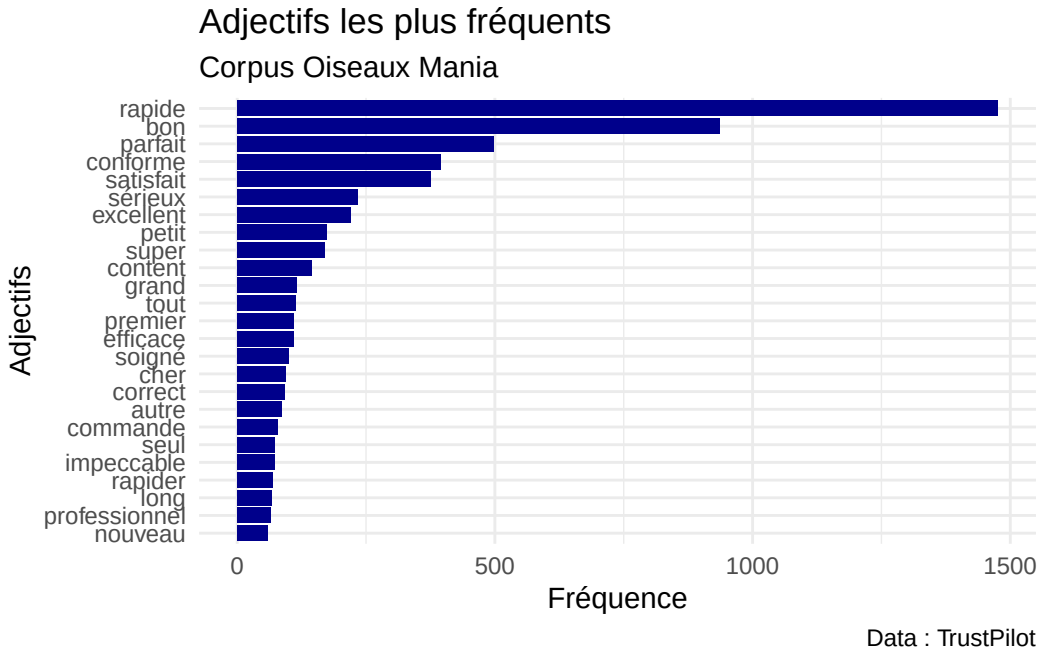


```
vocab2<-ann_token%>%
  filter(upos=="NOUN" | upos=="VERB" | upos=="ADJ")%>%
  summarise(freq=n(),.by=c(lemma,upos))%>%
  filter(freq>30)%>%
  mutate(angle= 90 * sample(c(0, 1), n(), replace = TRUE, prob = c(75, 25)))

library(ggwordcloud)
ggplot(vocab2)+
  geom_text_wordcloud_area(aes(label=lemma, size=freq, color=freq, angle=angle))+
  scale_size_area(max_size = 24)+
  scale_color_fermenter(palette = "Set2")+
  theme_minimal()
```

```
Warning in wordcloud_boxes(data_points = points_valid_first, boxes = boxes, :
Some words could not fit on page. They have been placed at their original
positions.
```


```
ggplot(vocab2)+
  geom_text_wordcloud_area(aes(label=lemma, size=freq, color=upos, angle=angle))+
  scale_size_area(max_size = 24)+
  scale_color_manual(values=c("ADJ"="orange","NOUN"="lightgreen","VERB"="purple"))+
  theme_minimal()
```

```
Warning in wordcloud_boxes(data_points = points_valid_first, boxes = boxes, :
One word could not fit on page. It has been placed at its original position.
```


répondre
conseiller
part
paquet
rapider
vendeur
redire
satisfaire
contre
cage
transport
falloir
heure
agréable
protéger
satisfait
mettre
nouveau
prendre
réception
décevoir
facile
mois
harnais
site
expérience
apprécier
coli
dire
rapport
premier
description
avoir
fait
donner
commander
client
rester
gris
prix
envoyer
satisfaire
aller
excellent
intéressant
commande
envole
colis
même
recommander
ligne
soigné
sérieux
cher
demander
commander
rupture
article
personne
conseil
besoin
accueil
voir
habitude
étoile
bon
livraison
commande
rapide
envoi
conforme
choix
large
correct
emballer
arriver
relais
point
équipe
produit
manier
communication
payer
pouvoir
délai
super
bémol
service
achat
être
magasin
passer
attente
autre
internet
oiseau
petit
tout
continuer
marchandise
réponse
trouver
qualité
commande
grand
produire
carton
mail
perroquet
professionnel
nourriture
graine
boutique
expédition
stock
frais
hésiter
problème
efficace
jouet
faire
long
manquer
content
écoute
fois
élevé
seul
livrer
top
port
penser
proposer
raisonnable
attendre
rapidité
perruche
correspondre
téléphone
recevoir
réactif
jour
fiable
parfait
temps
photo
impeccable
souci
expédier
respecter
emballage
acheter
tre
tre
beau
état
produit
suivre
adorer
devoir
produire
savoir

19 Les dépendances syntaxiques

Quels sont les mots associés aux termes cibles ?

```
#on met à niveau la racine
ann_racine<- ann_token%>%
  left_join(ann_token,by= c("doc_id"="doc_id", "sid"="sid", "tid_source"="tid"), suffix=c("" 
#on filtre les relation nominales puis celle qui concerne les termes cibles
foo<-ann_racine %>%
  filter(relation == "amod"|relation =="acl"|relation =="nmod"|relation =="appos") %>%
  select(qual = lemma, source = lemma_source)%>%
  filter(source=="commande"|source=="livraison"|source=="produit"|source=="prix")%>%
  group_by(source,qual)%>%
  summarise(n=n())
```

```
`summarise()` has grouped output by 'source'. You can override using the
`.groups` argument.
```

```
# On remet en forme les données
foo1<-foo%>%
  pivot_wider(names_from = source, values_from = n)%>%
  mutate(across(everything(), ~replace_na(.x,0)))%>%
  mutate(sum=rowSums(.[,2:5]))%>%
  filter(sum>15)%>%
  select(-sum)%>%
  pivot_longer(!qual, names_to = "source", values_to = "n")



ggplot(foo1,aes(x=reorder(qual,n), y=n, group=source))+
  geom_bar(stat="identity",aes(fill=source),position=position_dodge())+
  coord_flip()+
  scale_fill_brewer(palette="Spectral",direction = -1)+
  theme_minimal()+
  labs( title="Analyse des dépendances nominales", subtitle = "les termes du site et du servi
  facet_wrap(~source, ncol = 4)
```

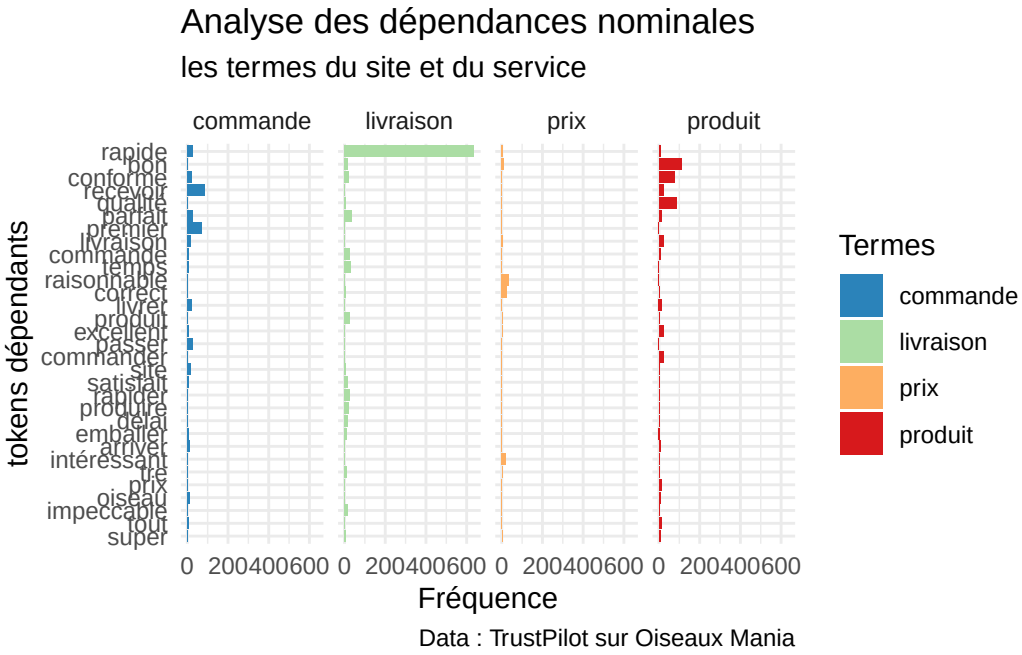
Analyse des dépendances nominales
les termes du site et du service
commande
livraison
prix
produit
tokens dépendants
rapide
bon
conforme
recevoir
qualité
parfait
premier
livraison
commande
temps
raisonnable
correct
livrer
produit
excellent
passer
commander
site
satisfait
rapider
produire
delai
emballer
arriver
intéressant
tre
prix
oiseau
impeccable
tout
super
0 200400600 0 200400600 0 200400600 0 200400600
Fréquence
Termes
commande
livraison
prix
produit
Data : TrustPilot sur Oiseaux Mania

20 *Topic Analysis*

```
library(readxl)
library(tidyverse)
library(quanteda)
library(quanteda.textstats)
library(quanteda.textplots)
library(RColorBrewer)
library(topicmodels)
library(ggwordcloud)
```

21 Les données

```
data <- read_csv("data/data_trustpilot_oiseaux.csv")
```

```
Rows: 4388 Columns: 7
-- Column specification --------------------------------------------------------
Delimiter: ","
chr (4): auteur, date, month, comments
dbl (3): id, year, note

i Use `spec()` to retrieve the full column specification for this data.
i Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

22 *Topics Analysis*

On va maintenant s'intéresser à la détection et à l'analyse de topics. Il existe de nombreux algorithmes pour cela. On va en explorer un : le modèle LDA, pour Latent Dirichlet Allocation.

- Description du modèle LDA :

L'idée est la suivante : un corpus est considéré comme une collection de documents. Chaque document est considéré comme étant composé d'un mélange de topics. Chaque topic est considéré comme étant composé d'un mélange de tokens. L'algorithme calcule par itération les probabilités d'appartenance des tokens aux topics et des topics aux documents, ce qui nous permet de visualiser la composition des sujets identifiés.

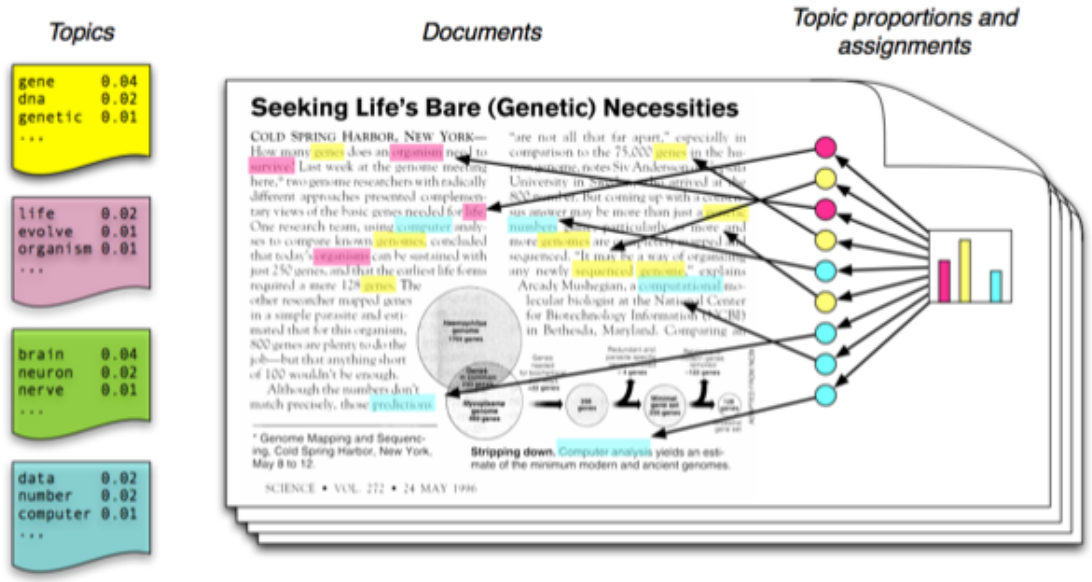

Figure source: Blei, D. M. (2012). Probabilistic topic models. *Communications of the ACM*, *55*(4), 77-84.

Figure 22.1: Le modèle LDA

22.1 Le modèle LDA avec topicmodels

On travaille à partir du dfm. On doit transformer le format des données afin de l'injecter dans le modèle. On réduit le nombre de termes considérés, ce qui permet de réduire les temps de calcul et de trouver une solution convergente.

```
corpus_oiseaux<-corpus(data, text_field = "comments")

tok<-tokens(corpus_oiseaux, remove_punct = TRUE, remove_numbers = TRUE, remove_symbols = TRU
  tokens_remove(stopwords("fr"))

dfm<-dfm(tok)


#On filtre les mots trop et trop peu fréquents
rem<-c("très","rapide","produit","livraison", "commande", "bien", "site", "a", "bon", "merci

news_dfm <- dfm %>%
  dfm_remove(rem)%>%
  dfm_trim(min_termfreq = 0.8, termfreq_type = "quantile",     # 80% des mots les plus fréquer
           max_docfreq = 0.2, docfreq_type = "prop")           #qui apparaissent dans max 20%

#On supprime les entrées vides
news_dfm <- news_dfm[ntoken(news_dfm) > 0,]

#On transforme en dtm, un format compris par le package topicsmodel
dtm <- convert(news_dfm, to = "topicmodels")

#On lance le modèle
lda <- LDA(dtm, k = 5)

#On regarde les résultats
terms(lda,10)
```

```
      Topic 1      Topic 2      Topic 3    Topic 4      Topic 5
 [1,] "produits"   "j'ai"       "super"    "produits"   "j'ai"
 [2,] "rien"       "emballé"    "qualité"  "qualité"    "rapidité"
 [3,] "rapidement" "reçu"       "mania"    "satisfaite" "oiseaux"
 [4,] "conforme"   "satisfaite" "prix"     "colis"      "reçu"
 [5,] "service"    "toujours"   "bonne"    "reçu"       "c'est"
 [6,] "prix"       "colis"      "problème" "toujours"   "colis"
 [7,] "oiseaux"    "produits"   "tout"     "rapidement" "qualité"
```

```
 [8,] "choix"      "plus"       "oiseaux"  "envoi"      "tout"
 [9,] "satisfait"  "envoi"      "tres"     "oiseaux"    "produits"
[10,] "temps"      "prix"       "chez"     "j'ai"       "service"
```

```
# topics(lda)

corpus_oiseaux["text996"]
```

```
Corpus consisting of 1 document and 6 docvars.
text996 :
"Seconde commande, satisfaction totale, expédition très rapid..."
```

```
corpus_oiseaux["text995"]
```

```
Corpus consisting of 1 document and 6 docvars.
text995 :
"Très bon produit. Livraison rapide et sérieux je recommande ..."
```

```
corpus_oiseaux["text999"]
```

```
Corpus consisting of 1 document and 6 docvars.
text999 :
"Très bon magasin emballage dans les normes on y trouve de to..."
```

22.2 *Topic Analysis* à partir de l'annotation des *part of speech*

Les résultats du modèle LDA sont très dépendants de la qualité du vocabulaire injecté. Plus on travaille ce vocabulaire, meilleurs sont les résultats. On va donc reprendre tout ce qu'on a fait jusqu'à présent pour améliorer les résultats de notre modèle : on récupère les annotations ; on filtre le vocabulaire pour ne garder que les noms, adjectifs et verbes ; on crée les collocations ; on filtre les occurrences trop et pas assez fréquentes.

```
ann_token<-read_rds("data/annotation_oiseaux.rds")


data<-ann_token%>%
  filter(upos=="NOUN"|upos=="VERB"|upos=="ADJ")%>%
  group_by(doc_id)%>%
```

```
  summarise(text=paste(lemma,collapse = " "))%>%
  inner_join(data, join_by("doc_id"=="id"))

corpus_new<-corpus(data, text_field = "text")
toks<-tokens(corpus_new)%>%
  tokens_replace(c("produire", "conformer","colir"), c("produit", "conforme","colis"))%>%
  tokens_remove(c(".",","))

colloc<-textstat_collocations(toks, min_count = 10, tolower = TRUE)

toks<-tokens_compound(toks, pattern = colloc[colloc$z>7,])


dfm_new<-dfm(toks)%>%
  dfm_trim(min_termfreq = 0.6, termfreq_type = "quantile",
           max_docfreq = 0.1, docfreq_type = "prop")
dtm_new <- convert(dfm_new, to = "topicmodels")

set.seed(1234)
lda <- LDA(dtm_new, k = 5)

term<-as_tibble(terms(lda,25))%>%
  mutate(rank=as.numeric(row.names(.)))%>%
  pivot_longer(-rank, names_to = "topic",values_to = "term")

ggplot(term, aes(x=topic, y= rank, group =  term , label = term)) +
  scale_y_reverse() +
  geom_text(aes(color=topic,size=8/log(rank)))+
  theme_minimal()+
  scale_color_hue()+
  guides(color="none",size="none")
```

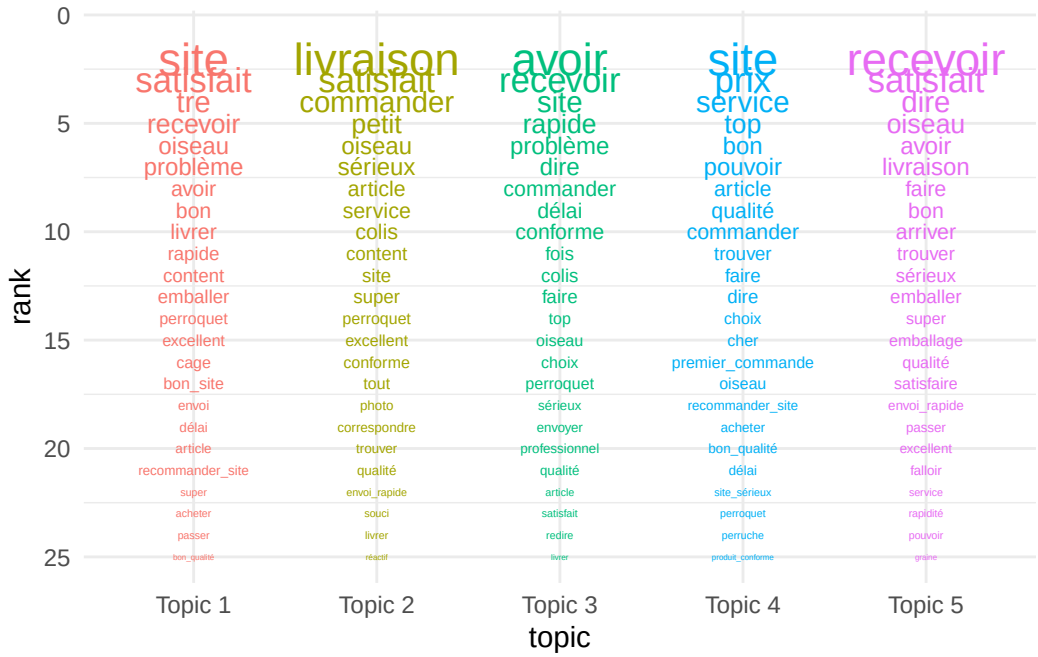

22.3 Déterminer le nombre de topics optimal

Le modèle LDA fonctionne à partir d'un nombre de topics donné. La question est donc de savoir quel est le nombre de topics optimal pour décrire notre corpus. Heureusement, des personnes ont créé des fonctions et des procédures pour nous aider dans cette quête. L'idée est de calculer différents modèles pour différents nombres de topics, et de comparer la qualité des résultats. La procédure ci-dessous est en deux parties :

- Tout d'abord, on compare la qualité de différents indicateurs sur un grand nombre de modèles, pour aboutir à une liste de quelques solutions à comparer plus en détail (de 3 à 10).
- Ensuite, on compare les résultats de la liste réduite de modèles, pour déterminer lequel a la meilleure distribution des topics entre les documents. La distribution recherchée est celle qui distingue le plus les documents en fonction des topics, tout en étant à droite de l'estimation d'une répartition uniforme des documents entre les topics. Le critère de parcimonie nous invite à choisir la solution avec le moins grand nombre de topics, en cas de résultats comparables.

```
##Etape 1 : les meilleures solutions
library(ldatuning)
library(magrittr)
```

```
Attachement du package : 'magrittr'

L'objet suivant est masqué depuis 'package:purrr':

    set_names

L'objet suivant est masqué depuis 'package:tidyr':

    extract
```

```
result <- FindTopicsNumber(dtm_new,
                           topics = c(seq(from = 2, to = 9, by = 1), seq(10, 25, 5)),
                           metrics = c("Griffiths2004", "CaoJuan2009", "Arun2010", "Deveaud2(
                           method = "Gibbs",
                           control = list(seed = 0:4,
                                          nstart = 5,
                                          best = TRUE),
                           mc.cores = 4L,
                           verbose = TRUE
                           )
```

```
fit models... done.
calculate metrics:
  Griffiths2004... done.
  CaoJuan2009... done.
  Arun2010... done.
  Deveaud2014... done.
```

```
FindTopicsNumber_plot(result)
```

```
Warning: The `<scale>` argument of `guides()` cannot be `FALSE`. Use "none" instead as
of ggplot2 3.3.4.
i The deprecated feature was likely used in the ldatuning package.
  Please report the issue at <https://github.com/nikita-moor/ldatuning/issues>.
```

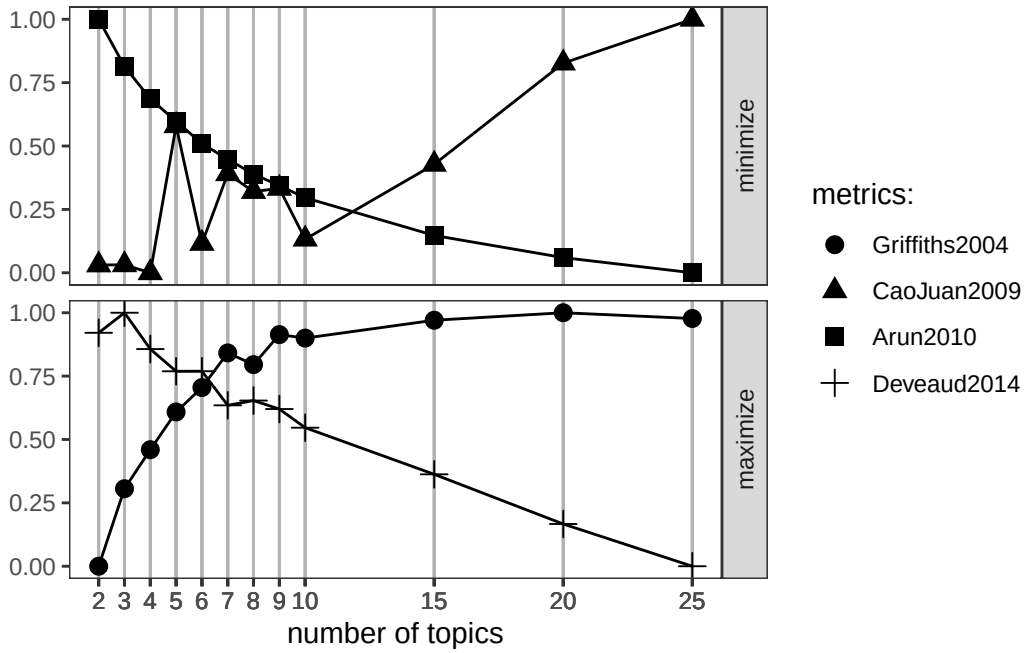


```
##Etape 2 : comparaison des solutions
para <- tibble(k = c(6,7,8,9,10))
lemma_tm <- para %>%
  mutate(lda = map(k,
                   function(k) LDA(
                     k=k,
                     x=dtm_new,
                     method="Gibbs",
                     control=list(seed = 0:4,
                                  nstart = 5,
                                  best = TRUE)
                     )
                   )
         )

lemma_tm <- lemma_tm %>%
  mutate(lda_gamma = map(.x=lda,
                         .f=tidytext::tidy,
                         matrix="gamma"))
lemma_tm %>%
  unnest(lda_gamma) %>%
  group_by(k, document) %>%
  arrange(desc(gamma)) %>%
```

```
  slice(1) %>%
  ungroup() %>%
  ggplot(aes(x=gamma, fill=factor(k))) +
  geom_histogram(bins = 20) +
  scale_fill_discrete(name = "Number of\nTopics") +
  xlab("maximum gamma per document") +
  facet_wrap(~k) +
  geom_vline(aes(xintercept = 1/k),
             tibble(k=lemma_tm %$% unique(k)),
             color="darkred")
```

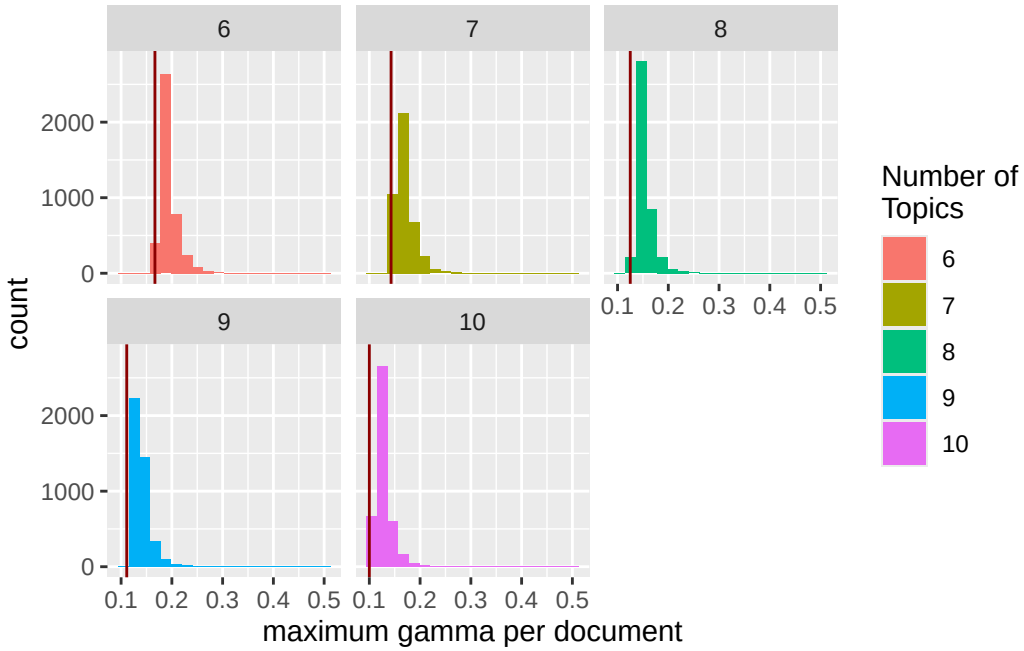

22.4 Représentation graphique

À partir de la solution retenue aux étapes précédentes, on va représenter les différents topics :

```
set.seed(1234)     #pour la réplicabilité des résultats
lda <- LDA(dtm_new, k = 9)

lda_res<-as.data.frame(terms(lda, 25))%>%
  rename(nom1='Topic 1',nom2='Topic 2', nom3='Topic 3', nom4='Topic 4', nom5='Topic 5',nom6=
```

```
  mutate(rank=as.numeric(row.names(.)))%>%
  pivot_longer(-rank, names_to = "topic", values_to = "term")

ggplot(lda_res, aes(x=topic, y= rank, group =  term , label = term)) +
  scale_y_reverse() +
  geom_text(aes(color=topic,size=8/log(rank)))+
  theme_minimal()+
  scale_color_hue()+
  guides(color=FALSE,size=FALSE)
```

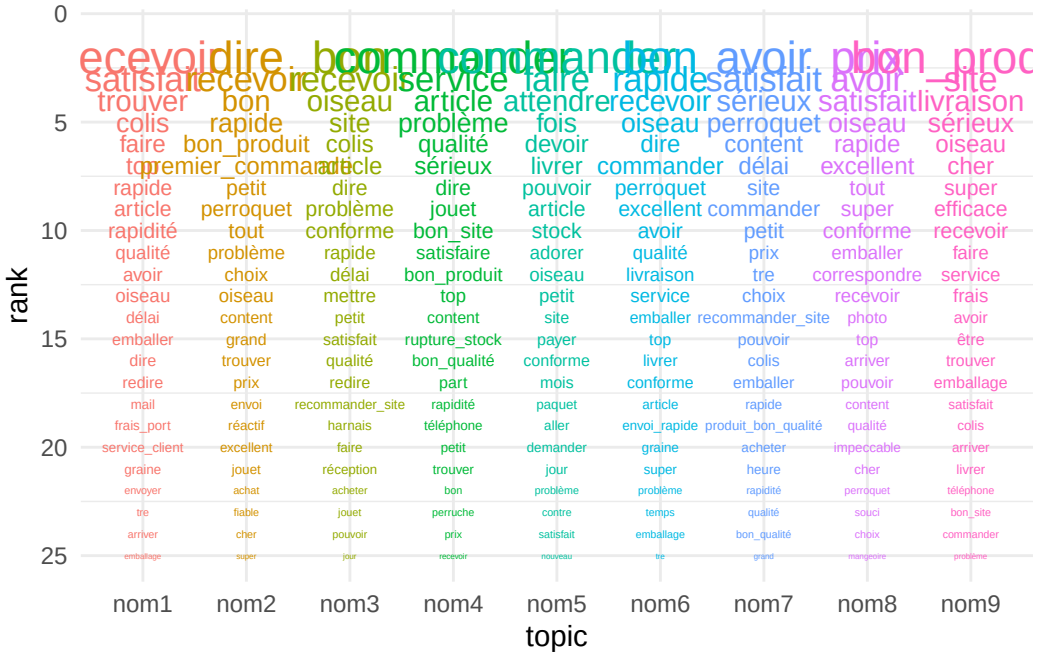

23 *Theory-Driven LDA*

Ici, on va forcer les *topics* grâce à la réalisation d'un dictionnaire. C'est utile quand on cherche à appliquer une théorie qui nous dit ce que l'on cherche à trouver. Par exemple, ici on s'intéresse aux attributs clés des logements oiseaux. Dans d'autre cas, on pourra chercher à expliquer les notes en fonction de *topics* qui reflètent les attributs clés. On peut réaliser le dictionnaire a priori ou après différentes analyses de *topics*, de co-occurences, de fréquence, etc.

On commence par créer un dictionnaire.

```
dict<-dictionary(list(produit=c("produit*", "cage","oiseau","graine*"),
                      livraison=c("livr*","recepti*","délai"),
                      commande=c("command*","emballage","envoi*"),
                      site="*site*",
                      prix=c("*prix*","frais_port")
                      ))
dict
```

```
Dictionary object with 5 key entries.
- [produit]:
  - produit*, cage, oiseau, graine*
- [livraison]:
  - livr*, recepti*, délai
- [commande]:
  - command*, emballage, envoi*
- [site]:
  - *site*
- [prix]:
  - *prix*, frais_port
```

```
head(dfm_lookup(dfm_new,dict))
```

```
Document-feature matrix of: 6 documents, 5 features (73.33% sparse) and 6 docvars.
    features
docs produit livraison commande site prix
   1       0         0        0    0    0
```

```
2       0         2         1     0     0
3       2         1         0     0     0
4       0         0         1     0     0
5       0         1         0     0     0
6       0         1         0     1     0
```

On utilise ensuite le package 'seededlda' pour lancer le modèle semi-supervisé.

```
library(seededlda)
```

```
Le chargement a nécessité le package : proxyC
```

```
Attachement du package : 'proxyC'
```

```
L'objet suivant est masqué depuis 'package:stats':

    dist
```

```
Attachement du package : 'seededlda'
```

```
Les objets suivants sont masqués depuis 'package:topicmodels':

    terms, topics
```

```
L'objet suivant est masqué depuis 'package:stats':

    terms
```

```
set.seed(1234)
slda<-textmodel_seededlda(dfm_new, dict, residual = T)
terms(slda,20)
```

```
      produit                     livraison
 [1,] "oiseau"                    "livraison"
 [2,] "cage"                      "livrer"
 [3,] "graine"                    "délai"
 [4,] "perroquet"                 "dire"
```

```
 [5,] "produit_qualité"              "bon_produit"
 [6,] "produit_conforme"             "satisfaire"
 [7,] "avoir"                        "problème"
 [8,] "content"                      "satisfait"
 [9,] "trouver"                      "service"
[10,] "petit"                        "bon"
[11,] "jouet"                        "top"
[12,] "acheter"                      "livraison_rapide_produit"
[13,] "harnais"                      "livraison_rapide_recommander"
[14,] "perruche"                     "temps"
[15,] "produit_bon_qualité"          "cher"
[16,] "grand"                        "impeccable"
[17,] "produit_conforme_description" "emballer"
[18,] "tout"                         "livreur"
[19,] "passer"                       "livraison_temps"
[20,] "arriver"                      "correct"
      commande              site               prix
 [1,] "commander"           "site"             "prix"
 [2,] "recevoir"            "rapide"           "bon"
 [3,] "envoi_rapide"        "bon_site"         "excellent"
 [4,] "emballage"           "recommander_site" "qualité"
 [5,] "envoi"               "sérieux"          "service"
 [6,] "satisfait"           "site_sérieux"     "frais_port"
 [7,] "article"             "tre"              "top"
 [8,] "conforme"            "satisfait"        "article"
 [9,] "commande_recevoir"   "siter"            "magasin"
[10,] "emballer"            "redire"           "prix_raisonnable"
[11,] "envoi_rapide_soigné" "rapider"          "satisfait"
[12,] "commande_arriver"    "premier_commande" "professionnel"
[13,] "commande_passer"     "super_site"       "super"
[14,] "correspondre"        "super"            "équipe"
[15,] "problème"            "choix"            "réactif"
[16,] "content"             "autre_site"       "téléphone"
[17,] "commande_livrer"     "conseiller"       "bon_rapport_qualité_prix"
[18,] "rapidité"            "bon_produit"      "prix_correct"
[19,] "rapide"              "achat"            "trouver"
[20,] "envoie"              "hésiter"          "expédition_rapide"
      other
 [1,] "avoir"
 [2,] "faire"
 [3,] "colis"
 [4,] "pouvoir"
 [5,] "jour"
```

```
 [6,] "fois"
 [7,] "recevoir"
 [8,] "attendre"
 [9,] "dire"
[10,] "autre"
[11,] "aller"
[12,] "part"
[13,] "être"
[14,] "petit"
[15,] "devoir"
[16,] "problème"
[17,] "mettre"
[18,] "attente"
[19,] "voir"
[20,] "mail"
```

24 Expliquer les notes

Dans cette dernière partie, nous allons nous intéresser aux notes et tenter de les expliquer à l'aide de l'analyse de *topics*.

24.1 NPS

Dans un premier temps, nous allons regarder le Net Promoter Score (NPS), puis nous étudierons les discours des promoteurs, détracteurs et passifs.

Tout d'abord, nous créons nos catégories en fonction des notes.

```
col<- c("red","gold", "chartreuse")


data<-data %>%
  mutate(NPS=case_when(note<4~"Détracteurs",
                       note==4~"Passifs",
                       note>4~"Promoteurs"))


ggplot(data, aes(x=note))+
  geom_histogram(binwidth = 1, aes(fill=NPS))+
  labs( title= " Distribution des scores NPS",
        subtitle = paste("Moyenne du NPS de l'échantillon",round(mean(data$note),1)),
        caption = paste("Data : TrustPilot, n=",nrow(data)),
        y = "Fréquence")+
  scale_fill_manual(values=col)+
  theme_light()
```

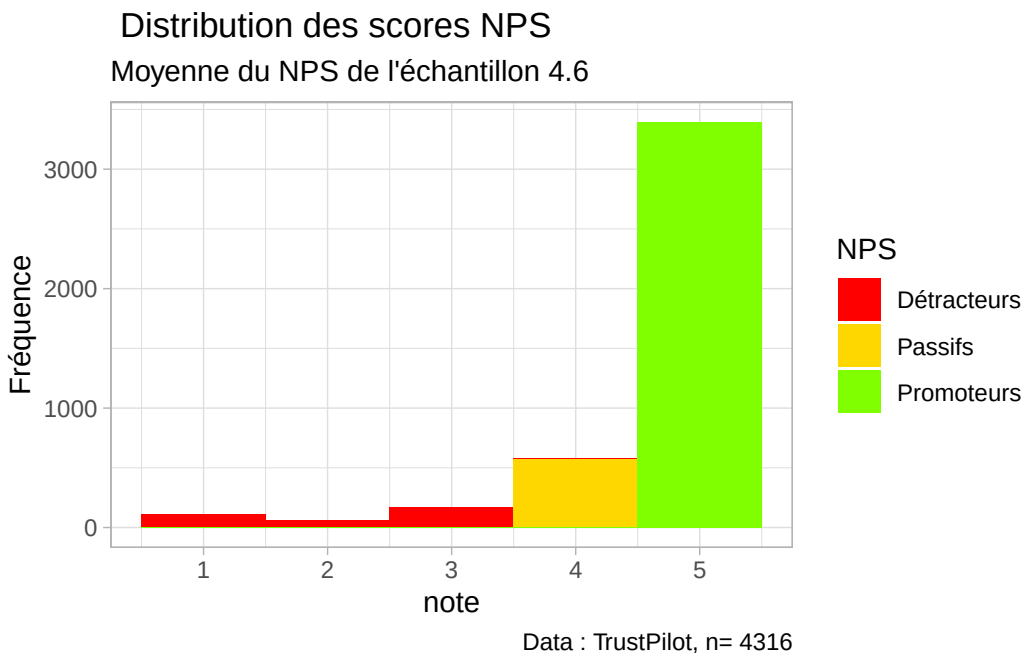

Puis nous réalisons un nuage de mots pour chaque groupe, afin d'avoir une idée de ce qui est exprimé.

```
dfm_new$NPS<-data$NPS
# docvars(toks)

dfm_gp <-dfm_new %>%
    dfm_group(groups = NPS)
# dfm_gp

stat<- dfm_gp %>%
  textstat_frequency(n = 30,  groups = NPS)
stat
```

```
       feature frequency rank docfreq       group
1        avoir       103    1       1 Détracteurs
2    commander        81    2       1 Détracteurs
3     recevoir        79    3       1 Détracteurs
4    livraison        77    4       1 Détracteurs
5        colis        41    5       1 Détracteurs
6         site        40    6       1 Détracteurs
7      pouvoir        38    7       1 Détracteurs
8      article        38    7       1 Détracteurs
```

9	livrer	37	9	1	Détracteurs
10	faire	34	10	1	Détracteurs
11	fois	31	11	1	Détracteurs
12	problème	28	12	1	Détracteurs
13	dire	28	12	1	Détracteurs
14	attendre	28	12	1	Détracteurs
15	jour	28	12	1	Détracteurs
16	devoir	28	12	1	Détracteurs
17	cher	26	17	1	Détracteurs
18	graine	26	17	1	Détracteurs
19	autre	25	19	1	Détracteurs
20	envoyer	25	19	1	Détracteurs
21	payer	25	19	1	Détracteurs
22	acheter	25	19	1	Détracteurs
23	trouver	23	23	1	Détracteurs
24	cage	23	23	1	Détracteurs
25	long	23	23	1	Détracteurs
26	oiseau	21	26	1	Détracteurs
27	déçu	21	26	1	Détracteurs
28	mois	21	26	1	Détracteurs
29	réponse	20	29	1	Détracteurs
30	semaine	20	29	1	Détracteurs
31	avoir	85	1	1	Passifs
32	livraison	78	2	1	Passifs
33	commander	56	3	1	Passifs
34	site	53	4	1	Passifs
35	recevoir	50	5	1	Passifs
36	rapide	42	6	1	Passifs
37	satisfait	41	7	1	Passifs
38	bon	40	8	1	Passifs
39	petit	35	9	1	Passifs
40	pouvoir	34	10	1	Passifs
41	perroquet	34	10	1	Passifs
42	colis	33	12	1	Passifs
43	oiseau	32	13	1	Passifs
44	trouver	30	14	1	Passifs
45	faire	29	15	1	Passifs
46	article	28	16	1	Passifs
47	frais_port	28	16	1	Passifs
48	cher	26	18	1	Passifs
49	problème	23	19	1	Passifs
50	dire	23	19	1	Passifs
51	bon_produit	21	21	1	Passifs

```
52      livrer        21   21       1     Passifs
53    emballer        21   21       1     Passifs
54       délai        20   24       1     Passifs
55  satisfaire        20   24       1     Passifs
56        cage        20   24       1     Passifs
57     arriver        19   27       1     Passifs
58        prix        19   27       1     Passifs
59   emballage        19   27       1     Passifs
60       super        18   30       1     Passifs
61      rapide       295    1       1  Promoteurs
62   satisfait       284    2       1  Promoteurs
63        site       279    3       1  Promoteurs
64   livraison       275    4       1  Promoteurs
65   commander       269    5       1  Promoteurs
66      oiseau       228    6       1  Promoteurs
67       avoir       222    7       1  Promoteurs
68    recevoir       186    8       1  Promoteurs
69         bon       173    9       1  Promoteurs
70     sérieux       157   10       1  Promoteurs
71        dire       150   11       1  Promoteurs
72     qualité       146   12       1  Promoteurs
73     service       143   13       1  Promoteurs
74         top       141   14       1  Promoteurs
75 bon_produit       138   15       1  Promoteurs
76   excellent       138   15       1  Promoteurs
77     article       134   17       1  Promoteurs
78       super       133   18       1  Promoteurs
79     content       127   19       1  Promoteurs
80   perroquet       122   20       1  Promoteurs
81     trouver       119   21       1  Promoteurs
82    problème       117   22       1  Promoteurs
83       faire       111   23       1  Promoteurs
84    emballer       111   23       1  Promoteurs
85    conforme       108   25       1  Promoteurs
86        prix        99   26       1  Promoteurs
87         tre        93   27       1  Promoteurs
88       délai        92   28       1  Promoteurs
89       petit        92   28       1  Promoteurs
90    rapidité        88   30       1  Promoteurs
```

```
ggplot(stat, aes(label = feature)) +
  geom_text_wordcloud(aes(size=log(frequency), color=group)) +
```

```
  theme_minimal()+
  facet_wrap(vars(group))+
  scale_color_manual(values=col)+
  labs(title="Nuage des 30 mots les plus fréquents (Par groupes)",
       caption = "La taille des mots est proportionnelle au log de leurs fréquences")
```

```
Warning in wordcloud_boxes(data_points = points_valid_first, boxes = boxes, :
Some words could not fit on page. They have been placed at their original
positions.
```

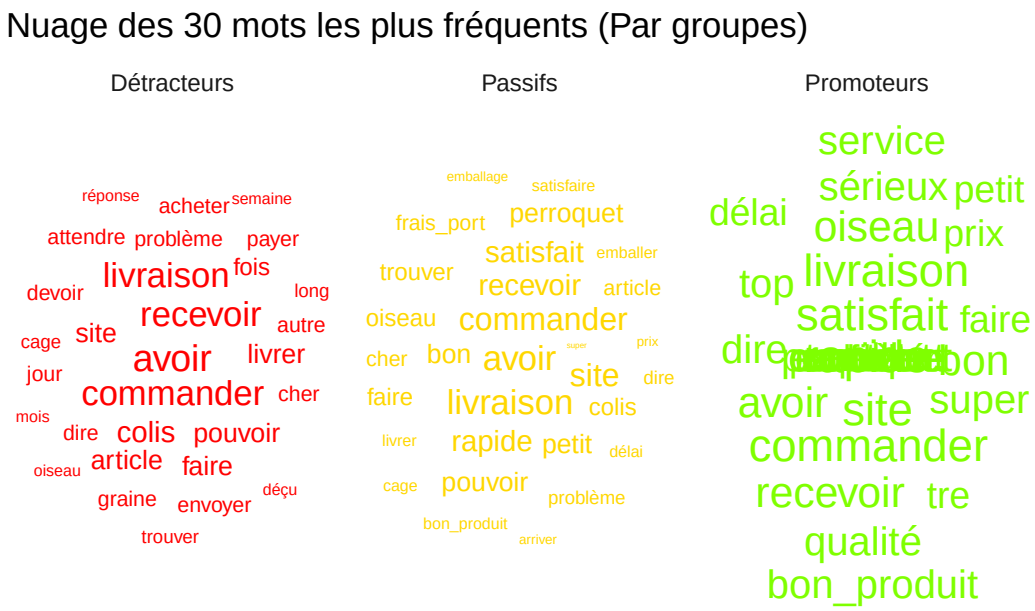

Maintenant, nous nous intéressons à ce qui caractérise chacun des groupes par rapport aux autres, grâce à la mesure du *keyness*.

```
graph_promoteur<-textstat_keyness(dfm_gp, target = "Promoteurs")%>%
  textplot_keyness(n = 30L, labelsize = 2,   show_legend = FALSE,
                   show_reference = FALSE,   color = c("Darkgreen", "gray"))+
  labs(x=NULL)


graph_detracteur <- textstat_keyness(dfm_gp, target = "Détracteurs" )%>%
  textplot_keyness(n = 30L, labelsize = 2,   show_legend = FALSE,
                   show_reference = FALSE,   color = c("firebrick", "gray"))+
```

```
  labs(x=NULL)


graph_passif <- textstat_keyness(dfm_gp, target = "Passifs")%>%
  textplot_keyness(n = 30L, labelsize = 2,   show_legend = FALSE,   show_reference = FALSE,
  labs(x=NULL)


library(cowplot)
```

```
Attachement du package : 'cowplot'

L'objet suivant est masqué depuis 'package:lubridate':

    stamp
```

```
p<- plot_grid(graph_detracteur, graph_passif ,graph_promoteur,  labels = c('Détracteurs', 'Pa

title <- ggdraw() + draw_label("NPS : Les raisons qui conduisent à la recommandation (keyness

note <- ggdraw()+ draw_text("Les valeurs représentent le keyness des termes.\nIl mesure leur


plot_grid(title, p,note, ncol=1, rel_heights=c(0.1, 1)) # rel_heights values control title ma
```

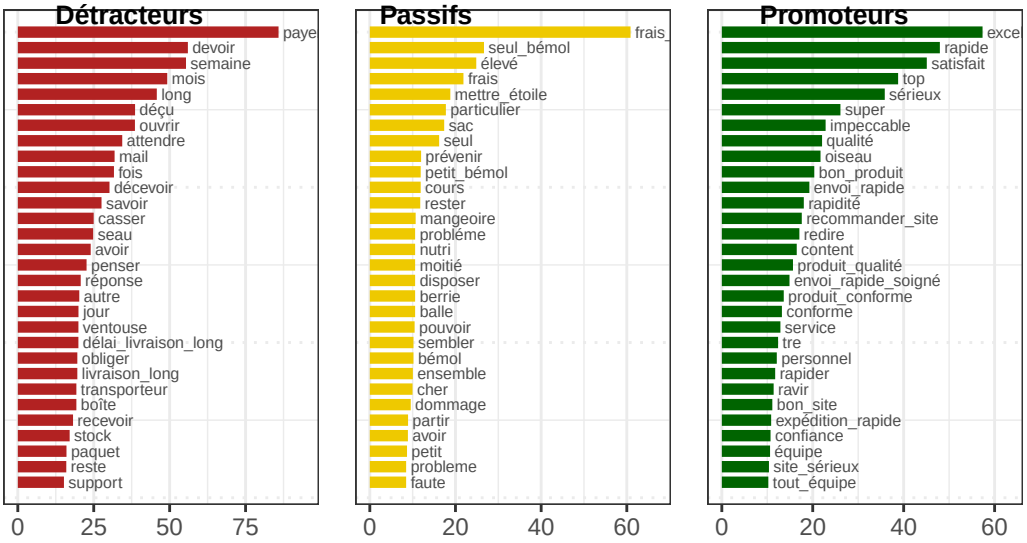

Les valeurs représentent le keyness des termes.
Il mesure leur caractère distinctif par une statistique du chi²

24.2 En fonction des topics

Maintenant, nous cherchons à voir la répartition des *topics* dans les notes, pour comprendre si certains *topics* contribuent plus ou moins à la satisfaction.

```
theta<-as.data.frame(slda$theta)%>%mutate(doc_id=as.numeric(row.names(.)))

data<-inner_join(data, theta)
```

```
Joining with `by = join_by(doc_id)`
```

```
foo<-data%>%select(note, produit, livraison, commande, site,prix, other)%>%
  pivot_longer(-note, names_to = "topic", values_to = "value")

ggplot(foo,aes(x=note, y=value, group=topic))+
  geom_bar(position="fill",stat="identity", aes(fill=topic))+
  scale_fill_brewer(palette="Spectral")+
  theme_minimal()
```

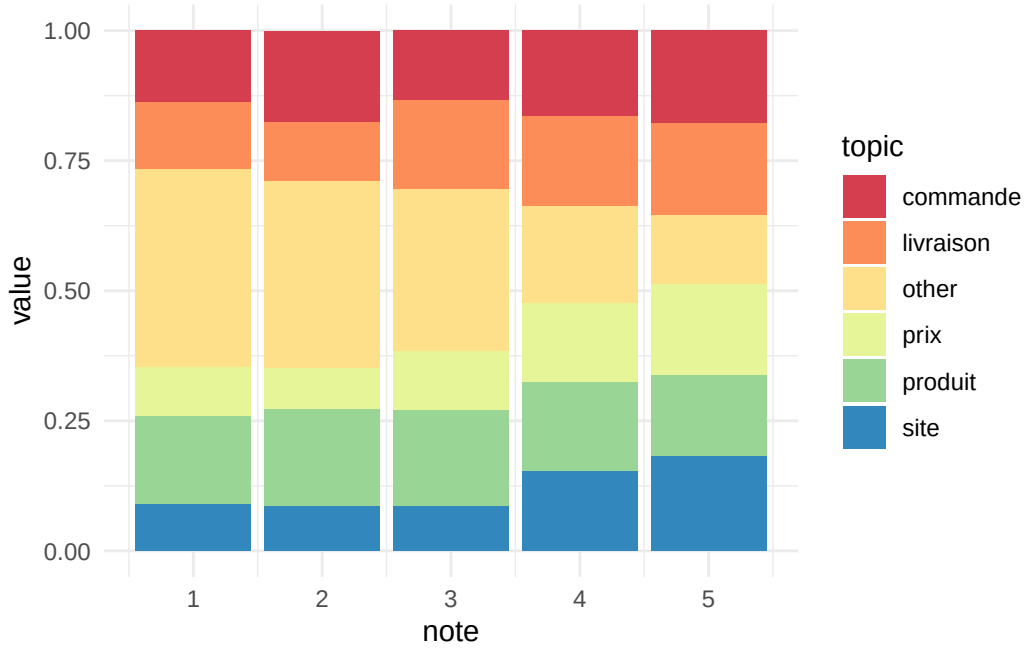


```
#Pour finir, une petite régression !
fit<-lm(note~produit+livraison+commande+site+prix, data =data)
summary(fit)
```

```
Call:
lm(formula = note ~ produit + livraison + commande + site + prix,
    data = data)

Residuals:
    Min      1Q  Median      3Q     Max
-4.1270 -0.0206  0.1766  0.3033  1.9858

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  2.51256    0.07178   35.01   <2e-16 ***
produit      1.92260    0.11146   17.25   <2e-16 ***
livraison    2.45543    0.10907   22.51   <2e-16 ***
commande     2.44823    0.10885   22.49   <2e-16 ***
site         2.95498    0.10736   27.52   <2e-16 ***
prix         2.79509    0.10718   26.08   <2e-16 ***
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.7591 on 4310 degrees of freedom
Multiple R-squared:  0.1952,    Adjusted R-squared:  0.1942
F-statistic:   209 on 5 and 4310 DF,  p-value: < 2.2e-16
```

A Webscraping

```
library(tidyverse)
library(scales)
library(quanteda)
library(quanteda.textstats)
library(httr)
library(rvest)
library(polite)

### Fichier TP_pets_website.csv

##### Scraping sites web
url_start<-"https://fr.trustpilot.com/categories/animals_pets"

trustpilot_website<-function(url_start){

session <- bow(url_start)
session$user_agent<-"Googlebot"
message("Scraping ", url_start)
page<-nod(session, url_start) %>%
  scrape(verbose=TRUE)
i<-page%>%html_elements(".styles_paginationWrapper__fukEb")%>%
  html_element("a.button_button__T34Lr:nth-child(5)")%>%
  html_text()%>%as.numeric()
website <- NULL

for (j in 1:i){
  url<-paste0(url_start,"?page=",j)
  Sys.sleep(5)
  session <- bow(url)
  session$user_agent<-"Googlebot"
  message("Scraping ", url)
  page<-nod(session, url) %>%
      scrape(verbose=TRUE)
```

```
    company_card <- page %>%
      html_elements("div.styles_wrapper__2JOo2:nth-of-type(n+4)")

    website_name <- company_card %>%
      html_element("p.typography_heading-xs__jSwUz") %>%
      html_text()

    nb_avis <- company_card %>%
      html_element("p.typography_body-m__xgxZ_")%>%
      html_text()

    localisation <- company_card%>%
      html_element("span.styles_metadataItem__Qn_Q2")%>%
      html_text()

    type <- company_card %>%
      html_element("div.styles_desktop__U5iWw") %>%
      html_text()

    lien <- paste0("https://fr.trustpilot.com", company_card %>%
                html_element("a")%>%html_attr("href"))


    website <- rbind(website, data.frame(
      website_name = website_name,
      nb_avis = nb_avis,
      localisation = localisation,
      type = type,
      lien = lien
    ))
  print(paste("page",j, "has been scraped"))

j<-j+1

}
return(website)

}

website<-trustpilot_website(url_start = url_start)

##### Création du fichier TP_pets_website.csv
```

```
website<-website%>%mutate(note=str_split_i(nb_avis,"\\|", 1)%>%
                        str_remove_all(., "[A-z]")%>%
                        str_replace(., ",", ".")%>%
                        as.numeric(),
                      nb_avis=str_split_i(nb_avis,"\\|",2)%>%
                        str_remove_all(., "[A-z]")%>%
                        str_remove_all(., "[:space:]")%>%
                        as.numeric()%>%
                        replace_na(.,0),
                      url_start=url_start,
                      nb_page=0,
                      cat=str_split(type, "·"))%>%
  unnest_wider(cat, names_sep = "_")

data_scrap<-website%>%filter(nb_avis>10)
write_csv(data_scrap, "TP_pets_website.csv")


### Fichier TP_pets_reviews.rds

##### Scraping reviews

trustpilot_reviews<-function(data){
  Sys.sleep(5)

  for (j in 1:nrow(data)) {
    i<-1
    b<-1


    while (b!="TRUE") {

      Sys.sleep(5)


      b<-http_error(paste0(data$lien[j], "?languages=all&page=", i))

      i<-i+1
      data$nb_page[j]<-i-2

    }
    print(paste0("nb_page of ", data$website_name[j], " has been fetched"))
```

```
}

i<-1
reviews <- NULL
# cat("\014")
cat(paste0("The script will run on ", sum(data$nb_page), " pages!\n"))
Sys.sleep(5)


for (j in 1: nrow(data)){
  for (i in 1:data$nb_page[j]){
    url<-paste0(data$lien[j],"?languages=all&page=",i)
    Sys.sleep(5)
    session <- bow(url)
    session$user_agent<-"Googlebot"
    message("Scraping ", url)
    page<-nod(session, url) %>%
      scrape(verbose=TRUE)

    review_card <- page %>%
      html_elements("div.styles_reviewCardInner__EwDq2")

    name <- review_card %>%
      html_element("span.typography_heading-xxs__QKBS8.typography_appearance-default__AAY1
      html_text()

    rating <- review_card %>%
      html_elements("div.star-rating_starRating__4rrcf.star-rating_medium__iN6Ty") %>%
      html_element("img")%>%
      html_attr("alt")%>%
      str_extract("[:digit:]")

    published <- review_card%>%
      html_elements(".styles_reviewContentwrapper__zH_9M")%>%
      html_element("p.typography_body-m__xgxZ_")%>%
      html_text()%>%
      str_remove("Date de l'expérience: ")

    verified <- review_card %>%
      html_element(".styles_detailsIcon__yqwWi") %>%
      html_text()
```

```
      title <- review_card %>%
        html_element("h2")%>%
        html_text()

      content <- review_card%>%
        html_elements(".styles_reviewContentwrapper__zH_9M")%>%
        html_element("p.typography_body-l__KUYFJ") %>%
        html_text2()


      reviews <- rbind(reviews, data.frame(
        website_name = data$website_name[j],
        name = name,
        rating = rating,
        published = published,
        verified = verified,
        title = title,
        content = content
      ))

      i<-i+1
    }
    print(paste0(data$website_name[j], " has been scraped"))

    j<-j+1
  }

  return(reviews)
}

hak<-trustpilot_reviews(data_scrap)
```

References

Balech, Sophie. 2022. “Une Application Du Modèle ELM (Elaboration Likelihood Model) Au Partage d’information Sur Twitter : Étude Du Rôle de La Forme Du Message Et Du Profil de l’émetteur:” *Innovations* n° 69 (3): 129–61. https://doi.org/10.3917/inno.pr2.0135.

Balech, Sophie, and Christophe Benavent. 2022. “Le Rôle Des Dimensions de l’expérience Dans La Satisfaction Client : Une Application Au Cas de l’industrie Hôtelière En Polynésie Française.” In *38ème Congrès Internation de l’AFM*, 28–38. Tunis, Tunisie.

Barron, Alexander T. J., Jenny Huang, Rebecca L. Spang, and Simon DeDeo. 2018. “Individuals, Institutions, and Innovation in the Debates of the French Revolution.” *Proceedings of the National Academy of Sciences* 115 (18): 4607–12. https://doi.org/10.1073/pnas.1717729115.

Boegershausen, Johannes, Hannes Datta, Abhishek Borah, and Andrew T. Stephen. 2022. “Fields of Gold: Scraping Web Data for Marketing Insights.” *Journal of Marketing* 86 (5): 1–20. https://doi.org/10.1177/00222429221100750.

Hartmann, Jochen, Mark Heitmann, Christina Schamp, and Oded Netzer. 2021. “The Power of Brand Selfies.” *Journal of Marketing Research* 58 (6): 1159–77. https://doi.org/10.1177/00222437211037258.

Kozlowski, Austin C, Matt Taddy, and James A Evans. 2019. “The Geometry of Culture: Analyzing Meaning Through Word Embeddings.” *American Sociological Review* 89 (5): 769–981. https://doi.org/10.1177/0003122419877135.

Kumar, Sunil, Arpan Kumar Kar, and P. Vigneswara Ilavarasan. 2021. “Applications of Text Mining in Services Management: A Systematic Literature Review.” *International Journal of Information Management Data Insights* 1 (1): 100008. https://doi.org/10.1016/j.jjimei.2021.100008.

Lefrançois, Alicia, Sophie Balech, and Sophie Changeur. 2022. “Transgression Et Consommation: Revue Intégrative Et Proposition d’un Agenda de Recherche.” In. Le Havre, France.

Liu, Angela Xia, Yilin Li, and Sean Xin Xu. 2021. “Assessing the Unacquainted: Inferred Reviewer Personality and Review Helpfulness.” *MIS Quarterly* 45 (3): 1113–48. https://doi.org/10.25300/MISQ/2021/14375.

Tirunillai, Seshadri, and Gerard J. Tellis. 2012. “Does Chatter Really Matter? Dynamics of User-Generated Content and Stock Performance.” *Marketing Science* 31 (2): 198–215. https://doi.org/10.1287/mksc.1110.0682.

Vannoni, Matia. 2022. “A Political Economy Approach to the Grammar of Institutions: Theory and Methods.” *Policy Studies Journal* 50 (2): 453–71. https://doi.org/10.1111/psj.12427.